证据契约驱动的加速器文档检索增强问答

Evidence-Contract-Driven Retrieval-Augmented Question Answering for Accelerator Technical Documents

摘要：加速器文档问答常因证据分散和条件遗漏而产生不完整回答。针对引用、编码与生成粒度失配，我们提出证据契约驱动的检索增强问答，通过引用与编码解耦、异构候选重排、需求到原文绑定贯通来源和完整性。系统覆盖 13 份 PDF、2,178 页、4,532 个证据块。在 21 条可回答问题上，完整 Hit@5 由 18/21 增至 20/21（95.2%，+9.5 pt）；32/32 条冻结请求成功返回，平均耗时 2.51 s。逐案分析同时定位父块与评分片段的完整覆盖差异及清单过度完整标记，为加速器静态知识服务提供可复核的工程实现与评测方法。

关键词：检索增强生成；证据契约；加速器知识库；跨语言检索；候选重排；可追溯问答

1 引言

本节结论：完整证据覆盖而非主题相关性，决定了加速器复合问题能否得到有据回答。

加速器工程查询会把设备、动作、条件和版本压缩进同一句问题。SHINE 主加速器的“工作模式与最终能量”要求两个事实；低温设备保护要求区分主联锁 PLC 与 CPLD；IOC 启动信息要求完整字段清单。这些问题的共同特征是：检索结果可以与问题高度相关，同时遗漏其中一个必需条件。以可执行的证据完整性约束连接检索与生成，是工程知识服务的核心问题。

现有系统在我们的语料中暴露出三种具体失效模式。第一，BGE-small-zh 直接编码时有 376/4,532 个输入超过 512 tokens，字符分块与模型预算发生错配。第二，主加速器父块完整包含所需证据，但实际送入重排的片段只保留局部内容。第三，初始摘录式回答给出能量却漏掉模式，仍返回完整状态。三种失效分别发生在输入表示、候选评分和回答覆盖层，单一相似度分数难以定位责任。

我们提出以证据契约贯通这三个层次的系统主张：来源身份固定，模型表示可变，完整性逐层可计算。系统将规范父块作为引用单位，将模型专用片段作为编码单位；以文档、物理页和原文摘录约束证据命中；再把用户要求、选中片段、生成主张与引用建立显式绑定。本文只覆盖静态文档问答。

领域语料使这种设计具有实际价值。实验物理与工业控制系统（EPICS）通过输入输出控制器（IOC）和过程变量（PV）组织设备访问，其技术标识需要精确保留 [1, 2]；SHINE 控制架构 [3] 与 European XFEL 设计资料 [4] 又包含不同装置、年代和参数定义。系统必须在中英文术语对应的同时恢复事实的所属对象与文档版本。

本文给出三条贡献：

(1) 提出引用与编码解耦的证据契约，在 13 份 PDF、2,178 页和 4,532 个可检索父块上实现稳定来源与 token 预算约束。

(2) 比较 11 种检索配置，以逐问题分析定位异构候选互补，将完整 Hit@5 由 18/21 提高到 20/21，净增 2 条且无反向翻转。

(3) 实现需求到原文的可追溯问答链，完成 32/32 条请求验证，平均 2.51 s，并定位 20/21 父块覆盖与 19/21 片段覆盖的粒度差异。

实验结果把系统选择建立在明确的成本与收益上。多查询改写使 E5 完整命中由 18 条降到 15 条，每条查询的平均检索调用量升至 2.844 倍，最终系统据此保留原始查询。双模型重排的两条新增命中来自 Qwen3 补充的候选，而 E5 原有 18 条命中全部保留。

逐项追溯还把回答完整性变成可诊断对象。冻结字段清单显示，一条 IOC 答案在内部核查中被标为支持，却遗漏部分必需字段。这个实例揭示了“来源支持某句话”与“回答覆盖用户全部要求”的判定差异，推动系统评价同时保留检索、片段与回答三个层次的证据。

2 相关工作

本节结论：本文把通用检索增强方法落实为可执行的工程证据契约，并逐层评价证据覆盖。

2.1 检索增强生成与归因

外部记忆支持知识密集型问答。RAG[5] 与 REALM[6] 结合检索和语言模型，FiD[7] 与 Atlas[8] 研究多片段融合和知识更新。长上下文位置效应 [9] 与 Self-RAG 的检索、反思机制 [10] 进一步说明上下文组织本身影响回答。本文与这些工作的差别是以固定物理来源贯通预训练组件，研究工程证据在各处理层的保留情况。

归因评价把事实支持拆成可检查单元。AIS[11]、Attributed QA[12] 和 ALCE[13] 分别定义来源支持、归因问答及引用质量，FActScore[14] 以原子事实评价长文本精度；RAGAs[15] 与 ARES[16] 评价检索上下文和生成忠实度。本文与之的差别是同时要求证据组完整覆盖、字段清单满足和 PDF 物理页解析，使遗漏与无来源陈述可以分开定位。

2.2 稠密检索与重排

稠密检索与重排提供互补的表示能力。DPR[17] 采用双编码器，ColBERT[18] 采用延迟交互，monoT5[19] 通过生成相关性标签完成排序。多语言 E5[20]、中文 BGE[21]、BGE-M3[22] 和 Qwen3[23] 扩展了跨语言及长文本表示；BEIR[24]、MTEB[25] 比较任务间迁移。本文与之的差别是固定规范父块和证据组，比较模型专用片段最终恢复的完整证据。

2.3 多路融合与查询扩展

多路融合需要以候选互补性解释收益。BM25[26] 提供词项统计基线，RRF[27] 以排名融合规避异构分数尺度，混合检索分析 [28] 揭示融合函数与参数的作用。HyDE[29] 及 Query2doc[30] 通过生成文本扩展查询。本文与之的差别是保留原始问题并复用冻结索引，通过调用计数、逐问题翻转及实际评分片段评价组合收益。

2.4 领域知识与加速器控制软件

加速器控制软件沉淀了可定位、强约束的工程事实。EPICS 体系及开发文档 [1, 2] 提供记录处理与通信语义；SHINE 的 IOC 管理 [31]、低温控制 [32]、快联锁 [33] 和 White Rabbit 定时 [34] 覆盖现场工程对象；XFEL 设计报告 [4] 提供跨装置参数参照。本文与这些工作的差别是把分散文献组织为静态知识服务，以完整证据而非控制执行作为评价对象。

3 问题定义与证据契约

本节结论：文档、物理页和摘录三元组将完整证据检索转化为确定性判断。

来源三元组固定了判定粒度。设文档集合为 $\mathcal{D}$，规范父块为 c，证据目标为 $t=(d,p,e)$，分别表示文档身份、从 1 开始的物理页与原文摘录。文本规范化函数 N 执行 NFKC、大小写与空白规范化，并处理特定英文换行断词。父块匹配规则为

$$M(c,t)=\mathbf{1}[d_c=d\ \wedge\ p\in[p_c^s,p_c^e]\ \wedge\ N(e)\preceq N(x_c)]\,. \tag{1}$$

式(1)中的 $\preceq$ 表示连续子串关系，因此同页其它块只有包含摘录才获得匹配。标注加载逐条验证每个目标同时存在于原始页和合格父块中。

证据组区分等价来源与互补事实。查询 q 具有 G_q 个组，第 g 组的备选目标集合为 $\mathcal{A}_{qg}$；前 K 个父块为 $\mathcal{R}_K(q)$。组内按 OR 判断，`all` 模式在组间执行 AND，`any` 模式在组间执行 OR：

$$a_{qg}(K)=\max_{c\in\mathcal{R}_K(q),\,t\in\mathcal{A}_{qg}}M(c,t),\qquad I_q(K)=\begin{cases}\prod_{g=1}^{G_q}a_{qg}(K), & \text{all},\\ \max_{g=1,\dots,G_q}a_{qg}(K), & \text{any}.\end{cases} \tag{2}$$

式(2)允许多个父块共同完成证据覆盖，保留复合问题中各事实的独立要求；空候选集的组覆盖取 0。

完整首次排名决定 Hit 与 MRR 的共同口径。对可回答集合 $\mathcal{Q}_+$，首次完整排名定义为 $r_q=\min\{k: I_q(k)=1\}$，前 5 项均未完成时取 $r_q=\infty$。指标为

$$\mathrm{Hit@}K=\frac{1}{|\mathcal{Q}_+|}\sum_{q\in\mathcal{Q}_+}I_q(K),\quad \mathrm{MRR@5}=\frac{1}{|\mathcal{Q}_+|}\sum_{q\in\mathcal{Q}_+}h(r_q),\quad h(r)=\begin{cases}1/r, & r\le 5,\\ 0, & r>5.\end{cases} \tag{3}$$

式(3)仅以可回答问题为分母。负例单独统计回答状态，检索、片段与生成三个评价层保留各自的判定单位。

4 证据契约驱动的系统

本节结论：稳定引用、token 安全表示和逐要求问答共同构成可追溯的数据链。

4.1 语料治理与引用身份

页内分块使来源定位保持稳定。登记表保存文档 ID、标题、版本、语言和主题；PyMuPDF 提取文本块及坐标，清洗器保守处理重复页边文本、英文断词和双栏顺序。`pdf-chunks-v3` 按段落、句子和空白优先分割，默认上限 1,200 字符、软下限 300 字符，规范块保持页内、无重叠。块 ID 由算法版本、配置、文档与版本、页、序号和文本共同计算 SHA-256。

检索准入保留可用正文并隔离主要损坏。4,537 个规范块中，4,532 个进入检索；排除项为数字或出版代码块 1 个、套话块 1 个和主要含替换字符的块 3 个。损坏排除同时要求替换字符不少于 8 个、占非空白字符不少于 20%。图1展示规范身份与模型表示的分离。

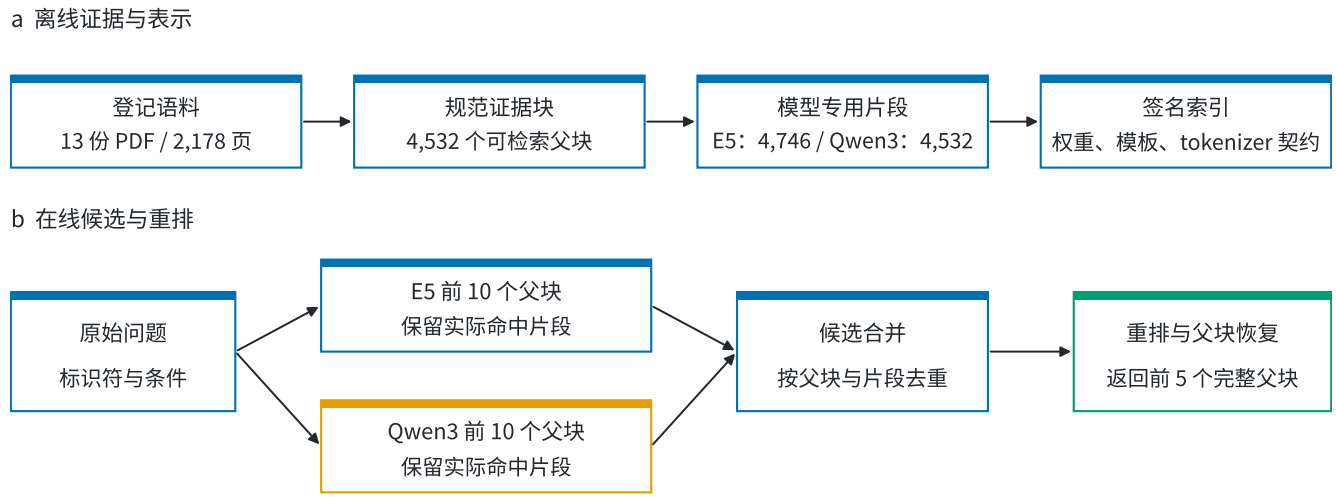


图 1 引用与编码解耦使两路模型共享 4,532 个规范父块。E5 和 Qwen3 分别产生 4,746 和 4,532 个片段，原始问题各取前 10 个父块合并后重排。

4.2 模型专用片段与签名索引

完整模板计数消除了模型输入超限。超长父块按 tokenizer 字符偏移分割，片段始终是父文本的精确子串，保留父块 ID 与字符范围。初始正文预算为

$$B_m = L_m - H_m - G, \qquad G = 16, \qquad O = 32, \tag{4}$$

其中 L_m 为模型上限，H_m 为标题、前缀及特殊 token 开销，G 为保护余量，O 为重叠 token 数。式(4)用于需拆分的输入；完整模板重新计数后才写入向量。已适配的父块直接编码，查询结果按实际命中片段恢复父块：

$$s_m(q,c) = \max_{p \in \mathcal{P}_m^{\mathrm{ret}}(c,q)} \frac{\boldsymbol{e}_m(q)^{\mathsf{T}} \boldsymbol{e}_m(p)}{\|\boldsymbol{e}_m(q)\|_2 \|\boldsymbol{e}_m(p)\|_2}. \tag{5}$$

式(5)取实际搜索返回的子片段集合，保留获胜片段原文及父块映射。

索引契约将向量空间兼容性变成启动约束。签名覆盖权重清单、模型与编码配置、tokenizer、查询与文档模板、维度、序列上限、归一化、距离及片段策略。相同维度的模型也使用独立契约。生产启动全量核验后冻结写入，检索请求复用验证结果；这种生命周期同时保留兼容性检查并降低全库重复扫描开销。

4.3 异构候选与片段重排

两路实际命中片段保留了候选互补信息。E5 与 Qwen3 各返回前 10 个父块，按父块 ID 合并；相同父块的不同获胜片段分别评分，相同文本去重。对照方案使用固定 $k = 60$ 的 RRF，最终方案使用 Qwen3-Reranker-0.6B

的 yes/no logits：

$$s_{\mathrm{RRF}}(q,c)=\sum_{m:\,c\in\mathcal{C}_m(q)}\frac{1}{60+\mathrm{rank}_m(q,c)},\qquad s_{\mathrm{rr}}(q,p)=\frac{e^{z_{\mathrm{yes}}}}{e^{z_{\mathrm{yes}}}+e^{z_{\mathrm{no}}}}. \tag{6}$$

式(6)分别提供排名融合分数和候选相关性分数。父块取其实际候选片段的最大重排分数，返回前 5 个完整父块。

4.4 需求、主张与原文绑定

显式要求把复合问题的覆盖变成逐项状态。模型先从原始问题提取 1 ~ 6 项事实要求；证据选择为每项绑定请求内 span；综合阶段只接收已支持要求和已验证片段。语义核查逐项审查主张与覆盖，失败后允许基于相同证据重写一次。图2给出从问题到最终状态的处理链。

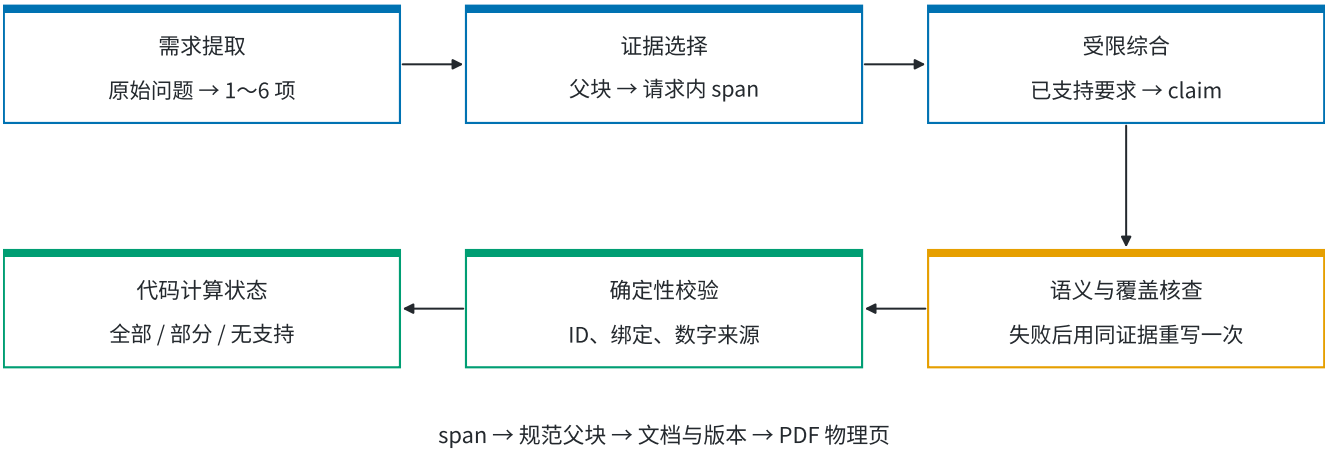


图 2 要求、片段、主张与原始 PDF 形成连续的来源链。代码核验身份与数字来源，支持标记经语义核查后用于计算三类状态。

确定性状态与来源解析固定了输出协议。全部要求支持时返回 `answered`，部分支持返回 `partial`，全部缺失返回 `insufficient`；时间规则处理实时状态缺口。代码将 span 映射为文档、版本、引文与物理页，网页用页内 PDF 查看器定位原文。`POST /v1/rag/answer` 只接收当前问题，共享 GPU 检索加锁，后续生成使用请求内状态。

5 实验设置

本节结论：统一 v2 标注和逐查询配对使 11 种配置的证据覆盖可直接复核。

语料覆盖三类文献来源与中英文技术表达。语料汇总见表1，包含 EPICS 开发资料、European XFEL 技术报告及 SHINE 专题资料。版本与物理页随引用保留，复现快照固定于 2026 年 10 月 27 日。

表 1 13 份 PDF 形成 2,178 页和 4,532 个可检索父块。规模按登记文档去重。

来源	文档数	物理页	规范块	可检索块
EPICS	2	809	1,919	1,918
European XFEL	4	834	2,019	2,019
SHINE	7	535	599	595
合计	13	2,178	4,537	4,532

冻结集将完整证据与无证据问题分开评价。21 条可回答问题包含 35 个证据组、13 条英文和 8 条中文；3 条含跨语言目标。11 条负例包含 3 条明显负例和 8 条针对指定时刻运行状态的领域负例。所有方法按式(3)返回 5 个父块；横向比较统一使用 `evidence-contract-v2`。

11 种配置覆盖表示、查询和排序三个选择维度。基线为 BM25、BGE-small-zh、BGE-base-zh、E5、BGE-M3 稠密表示与 Qwen3；扩展为 E5 多查询、Qwen3 多查询、语言路由、双模型 RRF 和双模型重排。多查询共享由 `qwen3-vl` 生成的最多 3 个改写，包含原始查询；路由按是否含汉字选择 E5 或 Qwen3。编码均复用本地冻结权重及签名索引。

配对重采样保留同一问题在各方法间的对应。我们以查询为单位进行 1,000 次有放回 bootstrap，固定 PCG64 seed 为 20261027，使用 2.5% 与 97.5% 线性分位数形成 95% 区间 [35]；E5 与最终方案采用相同重采样索引，并进行双侧精确 McNemar 检验 [36–38]。`paper_stats.py --check` 重算 231 条排名、32 条延迟和全部新增统计，并按可复现计算原则保存输入 SHA-256[39]。

服务验证固定了生成模型与硬件运行口径。完整 32 问于 2026 年 10 月 26 日使用 `qwen3.8-Flash-Next` 完成；E5、Qwen3 查询编码为 GPU FP32，重排为 GPU BF16。统计使用服务内部稳态计时，包括需求、证据选择、综合和核查。CPU 检索实验及 2026 年 10 月 27 日 `ds-1017` 代表性验证分别保留。

6 结果与机制分析

本节结论：双模型重排以两条新增完整命中兑现候选互补性，同时揭示证据粒度和清单核查的两个失配点。

6.1 主结果与配对效应

双模型重排把完整 Hit@5 从 0.857 提高到 0.952。表2比较 11 种配置；最终方案完整覆盖 20/21 条问题，MRR@5 为 0.607。BM25 的 MRR@5 为 0.627，首位命中为 0.524，说明精确词项具有较强早期排序能力；最终方案的主要收益是扩展前 5 项的完整覆盖。

表 2 双模型重排达到 20/21 完整命中。各方法使用同一查询集（n=21）、v2 标注和式(3)。

方法	Hit@1	Hit@3	Hit@5	MRR@5	完整数
BM25	0.524	0.762	0.762	0.627	16/21
BGE-small-zh	0.190	0.286	0.429	0.263	9/21
BGE-base-zh	0.143	0.476	0.619	0.311	13/21
E5	0.381	0.714	0.857	0.575	18/21
BGE-M3	0.333	0.714	0.762	0.510	16/21
Qwen3	0.333	0.619	0.810	0.511	17/21
语言路由	0.381	0.762	0.905	0.605	19/21
双模型 RRF	0.381	0.762	0.905	0.579	19/21
双模型重排	0.381	0.810	0.952	0.607	20/21
E5 多查询	0.381	0.619	0.714	0.516	15/21
Qwen3 多查询	0.333	0.619	0.810	0.485	17/21

配对分析把总体效应落实到两条翻转。E5 与最终方案共同命中 18 条、共同遗漏 1 条，正向翻转 2 条、反向翻转 0 条；Hit@5 差值为 0.095，95% 配对 bootstrap 区间为 [0.000,0.238]，精确 McNemar 检验 $p = 0.500$。MRR@5 差值为 0.032，区间为 [-0.131,0.187]。表3与图3给出四种主要方法的区间，逐问题机制见表4。

表 3 配对重采样刻画四种方法的分数波动。n=21，1,000 次，seed=20261027，95% 百分位区间。

方法	Hit@5 区间	MRR@5 区间
BM25	[0.571, 0.952]	[0.444, 0.810]
E5	[0.667, 1.000]	[0.413, 0.730]
Qwen3	[0.619, 0.952]	[0.344, 0.683]
双模型重排	[0.857, 1.000]	[0.472, 0.750]

6.2 输入安全与标注治理

token-safe 表示解决输入超限，其检索收益集中在一条问题。v1 标注下，BGE-small-zh 由直接编码的 8/21 提高至片段表示的 9/21，MRR@5 由 0.180 升至 0.204；4,950 个片段全部适配 512 tokens。新增命中的快联锁延迟证据原本位于可见范围，结果指向表示粒度对排序的影响；压缩器目标虽跨原截断边界，消除截断后仍被其它主题候选压过。

等价证据治理单独改变了分数而保持排名不变。审核对 11 条问题增加 39 个来源备选，备选总数由 37 增至

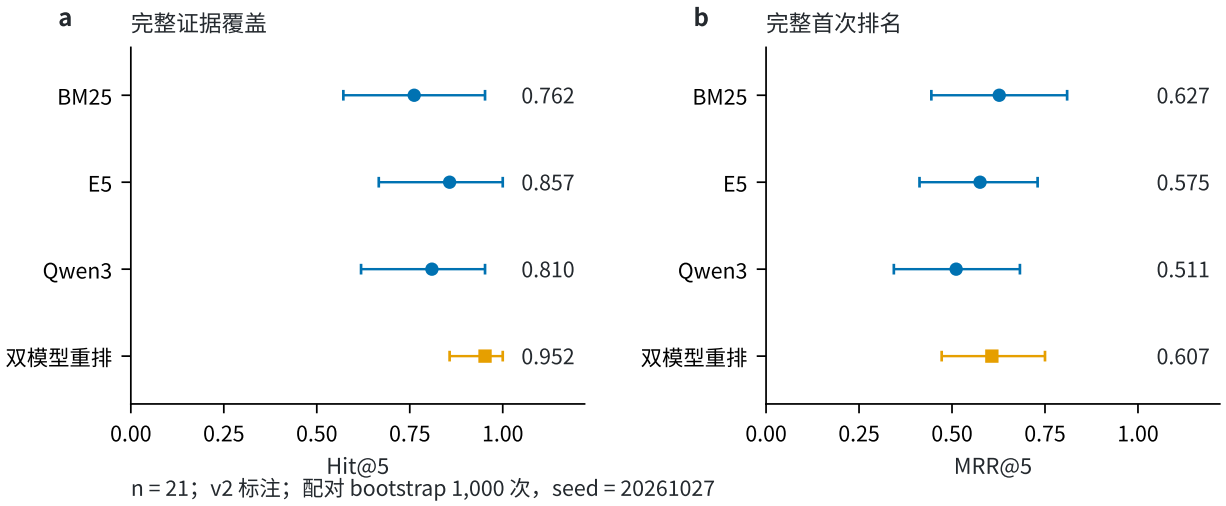


图 3 双模型重排把完整覆盖由 85.7% 提高到 95.2%，BM25 保持较高的首次完整排名得分。n=21，v2 标注，误差线为固定 seed 的 95% bootstrap 百分位区间。

76。相同 E5 排名经重判，Hit@5 从 16/21 变为 18/21；BM25 从 15/21 变为 16/21。这个可分离的标注效应使统一 v2 成为全部横向比较的前提，避免把来源补全写成排序收益。

6.3 互补候选与逐问题翻转

E5 与 Qwen3 的独有成功集合补足了两条最终增益。两者共同命中 15 条，E5 独有 3 条，Qwen3 独有 2 条，成功并集为 20 条。语言路由与 RRF 各达到 19/21，最终片段重排恢复全部 20 条候选完整问题。两条新增问题的 E5 前 10 个候选均缺失冻结目标，Qwen3 候选则完整包含所需证据；表4将增益定位为异构候选补充，E5 成功集合得到完整保留。

表 4 两条新增命中来自互补证据，反向翻转为 0。排名表示首次完整覆盖（n=21，v2）。

问题 ID	E5	Qwen3	重排	补足证据
`xfel-normal-energy`	外	2	3	XFEL 设计报告物理页 57，运行与最大能量定义
`cryo-interlock`	外	5	3	低温论文物理页 6，主 PLC 与 CPLD 保护链

三条原始候选轨迹解释了同主题召回与完整覆盖的差别。对 IOC 问题，E5 首位为控制设计幻灯片物理页 28，内容是静态信息与数据库管理；Qwen3 首位为 IOC 论文物理页 3 的面板描述，前 5 项只完成 1/2 组。对低温问题，E5 首位为快联锁论文物理页 2，涉及响应需求却缺少 PLC/CPLD 三组证据；Qwen3 定位低温论文物理页 6 并在前 5 项覆盖 3/3 组。对 XFEL 能量问题，E5 首位来自 SHINE 初设物理页 59；Qwen3 第二位定位 XFEL 报告物理页 57。原始分数、片段和 ID 保存在随文候选轨迹文件中。

6.4 证据粒度与语言分层

父块与评分片段的完整覆盖相差 1 条。候选父块完整 20/21，实际评分片段完整 19/21，最终父块完整 20/21，获胜片段完整 19/21；差异集中在主加速器问题。其完整父块同时包含模式与能量，获胜片段只保留局部内容。图4a 将这一差异定位到重排输入，而生成阶段获得恢复后的完整父块。

中文与跨语言问题解释了模型互补的主要来源。表5显示，E5 与最终方案在 13 条英文问题上均为 13/13；8 条中文问题由 5/8 提高到 7/8。3 条跨语言目标中，Qwen3 和最终方案均覆盖 2/3，而 E5 为 0/3。跨语言目标是证据语言切片，与中文、英文分组存在重叠。

6.5 多查询的成本收益与服务延迟

多查询增加调用却降低 E5 的完整覆盖。32 问各执行 91 次检索，相对原始 32 次为 2.844 倍；21 条可回答问题各执行 69 次，为 3.286 倍。E5 完整命中由 18/21 降至 15/21，下降 14.286 个百分点；Qwen3 保持 17/21 且 MRR@5 由 0.511 降至 0.485。记录的查询评测总耗时分别为 111.568 s 和 138.446 s，平均 3.486 s 和 4.326

表 5 增益集中在中文与跨语言目标。单元格为完整数/组内 n 及 Hit@5，跨语言行是重叠切片。

切片	BM25	E5	Qwen3	双模型重排
英文（n=13）	11/13（0.846）	13/13（1.000）	11/13（0.846）	13/13（1.000）
中文（n=8）	5/8（0.625）	5/8（0.625）	6/8（0.750）	7/8（0.875）
跨语言目标（n=3）	0/3（0.000）	0/3（0.000）	2/3（0.667）	2/3（0.667）

s。据此，最终系统选择原始查询加异构候选重排，图4b 展示覆盖代价。

32 条完整服务请求以平均 2.513 s 完成。21 条可回答问题返回 20 条 `answered` 与 1 条 `partial`，11 条负例全部返回 `insufficient`，31 条冻结集引用均解析到真实父块与 PDF 页。表6和图4c 显示延迟分布：可回答问题均值 3.337 s，中位数 3.178 s；全部请求 P95 为 4.152 s，最大值 5.056 s。按总时长聚合，稠密检索、重排及生成流程分别占 4.107%、8.996% 和 86.875%，生成核查构成主要耗时。

表 6 可回答问题与负例具有不同的延迟分布。单位为 s，分位数使用线性插值，计时包含全部问答处理阶段。

请求组	均值	P50	P95	最大值
全部（n=32）	2.513	2.924	4.152	5.056
可回答（n=21）	3.337	3.178	4.391	5.056
负例（n=11）	0.939	0.850	1.307	1.386

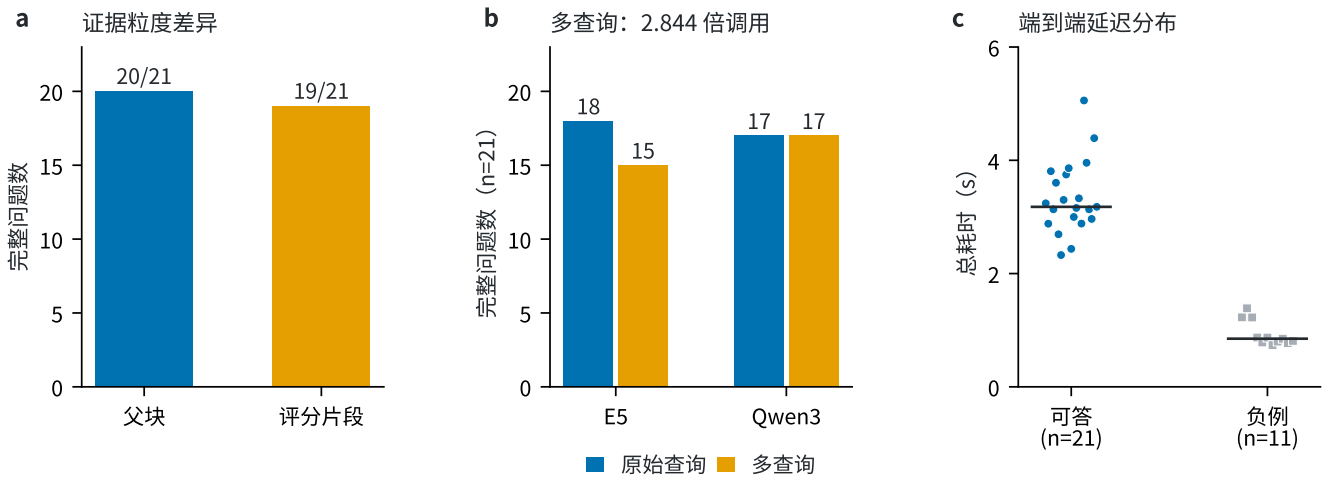


图 4 完整父块比评分片段多覆盖 1 条问题，多查询降低 E5 覆盖，生成流程主导服务耗时。a、b 采用 21 条问题的 v2 证据口径；c 为 2026 年 10 月 26 日 32 条请求，横线为组内中位数。

6.6 回答完整性的方向性失配

IOC 清单揭示了一次有来源但不完整的过度标记。内部流程将 32/33 个要求标为支持；IOC 答案列出地址、安装路径和 records，状态为 `answered`，却遗漏冻结清单中的启动时间、CA server 端口和 CA repeater 端口。20 条 `answered` 中至少 1 条存在该类字段缺口。该例把误差定位为“宽泛要求接受部分清单”，而不是引用身份错误。

低温和 XFEL 案例把回答覆盖与参数归属进一步分开。低温 PLC/CPLD 问题在最终检索中完整，但回答核查只保留 PLC 部分，明确返回 `partial`；这与 IOC 的过度完整标记方向相反。XFEL 能量问题中，原始首位候选还包含 FLASH 对象，第二位才提供目标装置的正常与最大能量定义；系统据文档、对象和版本分别组织参数。这三条轨迹共同支持分层追踪作为系统评价的必要接口。

7 讨论与效度威胁

本节结论：本系统的效度取决于证据构念、模型核查、查询分布和小样本推断四个因素。

构念效度由冻结证据组与问题语义共同决定。备选摘录经原文及合格块双重验证，但来源审核仍可能遗漏等价表达。IOC 清单的部分字段来自面板描述，“启动上报”与“界面展示”的语义边界值得独立复核；本文完整分数始终沿用冻结 v2 构念，文献出版年与本地版本标签分别保留。

内部效度受到核查器与生成器共享模型的影响。33 个模型提取要求与 35 个冻结证据组采用不同粒度，单个宽泛要求可以接受部分字段清单。IOC 实例证明存在过度完整标记，双人盲审将用于估计其发生率；数字与引用 ID 检查只验证可追溯性，语义支持仍由核查过程判定。

外部效度受开发查询与静态语料分布约束。21 条可回答问题已用于方案比较，3 条跨语言目标为重叠小切片；领域负例主要覆盖时间性缺口。独立保留集、复杂 PDF 结构和运行数据接口是后续扩展方向；`ds-1017` 仅完成代表性验证，本文 32 问服务指标固定归属 `qwen3.8-Flash-Next`。

结论效度通过配对效应与原始轨迹共同界定。两条不一致样本给出 $p = 0.500$，差值区间包含零，当前主张是候选互补机制与固定问题集上的完整覆盖改善。bootstrap 区间描述经验查询重采样波动，方法筛选、相关查询和多重比较影响总体推广；计时采用单次稳态记录，多查询规划耗时及同环境单查询对照缺失，跨 CPU/GPU 或模型版本的因果加速比留待受控测量。

8 结论与展望

本节结论：证据契约使加速器静态问答的完整覆盖、来源身份与生成状态可以联合审查。

我们以稳定父块、token 安全片段和索引签名形成引用与编码解耦的表示层，以证据组和逐要求绑定贯通检索及生成。13 份 PDF、2,178 页、4,532 个证据块上的 11 种配置比较显示，异构候选重排将完整命中从 18/21 提高至 20/21；32 条请求平均 2.51 s 完成。父块与片段覆盖差异、IOC 过度完整标记和多查询负收益，将系统评价从单一汇总得分推进到可定位的失效机制。

后续工作优先建设独立工程问题集与字段级人工评审，校准复合问题的覆盖判定；随后将复杂 PDF 证据恢复及运行数据接口纳入同一来源契约。固定硬件下的并发与尾延迟实验将进一步刻画系统的服务能力。

参考文献

[1] Leo R. Dalesio, Jeffrey O. Hill, Martin Kraimer, Stephen Lewis, Douglas Murray, Stephan Hunt, William Watson, Matthias Clausen, and John Dalesio. The experimental physics and industrial control system architecture: past, present, and future. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, 352(1-2):179–184, 1994. doi: 10.1016/0168-9002(94)91493-1.

[2] EPICS Collaboration. *EPICS Application Developer's Guide, Release 3.16.2*, 2018. URL https://epics.anl.gov/base/R3-16/2-docs/AppDevGuide.pdf. Accessed 2026-10-27.

[3] Yingbing Yan, Jianguo Ding, J. F. Chen, Guanghua Chen, et al. Status of the SHINE Control System. In *Proceedings of the 17th International Conference on Accelerator and Large Experimental Physics Control Systems*, pages 1481–1484, 2019. doi: 10.18429/JACoW-ICALEPCS2019-WEPHA167.

[4] Rafael Abela, A. Aghababyan, Massimo Altarelli, et al. XFEL: The European X-Ray Free-Electron Laser – Technical Design Report. Technical report, DESY, 2006.

[5] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems*, 2020. doi: 10.48550/arXiv.2005.11401. URL https://arxiv.org/abs/2005.11401.

[6] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Ming-Wei Chang. REALM: Retrieval-Augmented Language Model Pre-Training. In *Proceedings of the 37th International Conference on Machine Learning*, 2020. doi: 10.48550/arXiv.2002.08909. URL https://arxiv.org/abs/2002.08909.

[7] Gautier Izacard and Edouard Grave. Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering. In *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*, pages 874–880, 2021. doi: 10.18653/v1/2021.eacl-main.74.

[8] Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel, and Edouard Grave. Atlas: Few-shot Learning with Retrieval Augmented Language Models. *Journal of Machine Learning Research*, 24(251):1–43, 2023. doi: 10.48550/arXiv.2208.03299. URL https://arxiv.org/abs/2208.03299.

[9] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. doi: 10.1162/tacl_a_00638.

[10] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. In *The Twelfth International Conference on Learning Representations*, 2024. doi: 10.48550/arXiv.2310.11511. URL https://arxiv.org/abs/2310.11511.

[11] Hannah Rashkin, Vitaly Nikolaev, Matthew Lamm, Lora Aroyo, Michael Collins, Dipanjan Das, Slav Petrov, Gaurav Singh Tomar, Iulia Turc, and David Reitter. Measuring Attribution in Natural Language Generation Models. *Computational Linguistics*, 49(4):777–840, 2023. doi: 10.1162/coli_a_00486.

[12] Bernd Bohnet, Vinh Q. Tran, Pat Verga, Roee Aharoni, Daniel Andor, Livio Baldini Soares, Massimiliano Ciaramita, Jacob Eisenstein, Kuzman Ganchev, Jonathan Herzig, Kai Hui, Tom Kwiatkowski, Ji Ma, Jianmo Ni, Lierni Sestorain Saralegui, Tal Schuster, William W. Cohen, Michael Collins, Dipanjan Das, Donald Metzler, Slav Petrov, and Kellie Webster. Attributed Question Answering: Evaluation and Modeling for Attributed Large Language Models. *arXiv*, 2022. doi: 10.48550/arXiv.2212.08037. URL https://arxiv.org/abs/2212.08037.

[13] Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. Enabling Large Language Models to Generate Text with Citations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 6465–6488, 2023. doi: 10.18653/v1/2023.emnlp-main.398.

[14] Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 12076–12100, 2023. doi: 10.18653/v1/2023.emnlp-main.741.

[15] Shahul Es, Jithin James, Luis Espinosa Anke, and Steven Schockaert. RAGAs: Automated Evaluation of Retrieval Augmented Generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pages 150–158, 2024. doi: 10.18653/v1/2024.eacl-demo.16.

[16] Jon Saad-Falcon, Omar Khattab, Christopher Potts, and Matei Zaharia. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 338–354, 2024. doi: 10.18653/v1/2024.naacl-long.20.

[17] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen tau Yih. Dense Passage Retrieval for Open-Domain Question Answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781, 2020. doi: 10.18653/v1/2020.emnlp-main.550.

[18] Omar Khattab and Matei Zaharia. ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 39–48, 2020. doi: 10.1145/3397271.3401075.

[19] Rodrigo Nogueira, Zhiying Jiang, Ronak Pradeep, and Jimmy Lin. Document Ranking with a Pretrained Sequence-to-Sequence Model. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 708–718, 2020. doi: 10.18653/v1/2020.findings-emnlp.63.

[20] Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. Multilingual E5 Text Embeddings: A Technical Report. *arXiv*, 2024. doi: 10.48550/arXiv.2402.05672. URL https://arxiv.org/abs/2402.05672.

[21] Shitao Xiao, Zheng Liu, Peitian Zhang, Niklas Muennighoff, Defu Lian, and Jian-Yun Nie. C-Pack: Packed Resources For General Chinese Embeddings. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2024. doi: 10.48550/arXiv.2309.07597. URL https://arxiv.org/abs/2309.07597.

[22] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. *arXiv*, 2024. doi: 10.48550/arXiv.2402.03216. URL https://arxiv.org/abs/2402.03216.

[23] Yanzhao Zhang, Mingxin Li, Dingkun Long, Xin Zhang, Huan Lin, Baosong Yang, Pengjun Xie, An Yang, Dayiheng Liu, Junyang Lin, Fei Huang, and Jingren Zhou. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. *arXiv*, 2025. doi: 10.48550/arXiv.2506.05176. URL https://arxiv.org/abs/2506.05176.

[24] Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A Heterogenous Benchmark for Zero-shot Evaluation of Information Retrieval Models. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, 2021. doi: 10.48550/arXiv.2104.08663. URL https://arxiv.org/abs/2104.08663.

[25] Niklas Muennighoff, Nouamane Tazi, Loic Magne, and Nils Reimers. MTEB: Massive Text Embedding Benchmark. In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2014–2037, 2023. doi: 10.18653/v1/2023.eacl-main.148.

[26] Stephen Robertson and Hugo Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends® in Information Retrieval*, 4(1-2):1–174, 2009. doi: 10.1561/1500000019.

[27] Gordon V. Cormack, Charles L A Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, pages 758–759, 2009. doi: 10.1145/1571941.1572114.

[28] Sebastian Bruch, Siyu Gai, and Amir Ingber. An Analysis of Fusion Functions for Hybrid Retrieval. *arXiv*, 2022. doi: 10.48550/arXiv.2210.11934. URL https://arxiv.org/abs/2210.11934.

[29] Luyu Gao, Xueguang Ma, Jimmy Lin, and Jamie Callan. Precise Zero-Shot Dense Retrieval without Relevance Labels. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, 2023. doi: 10.48550/arXiv.2212.10496. URL https://arxiv.org/abs/2212.10496.

[30] Liang Wang, Nan Yang, and Furu Wei. Query2doc: Query Expansion with Large Language Models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023. doi: 10.48550/arXiv.2303.07678. URL https://arxiv.org/abs/2303.07678.

[31] Huihui Lv, Yingbing Yan, Qingru Mi, and Guanghua Chen. EPICS IOC and PVs Information Management System for SHINE. In *Proceedings of the 13th International Workshop on Emerging Technologies and Scientific Facilities Controls*, pages 107–109, 2023. doi: 10.18429/JACoW-PCaPAC2022-FRO21.

[32] Geyang Jiang, Qing Ni, Shuhua Wang, Jiuce Sun, Zhengrong Ouyang, Lei Zhang, Zilei Tong, and Yi Wang. The cryogenic control system of SHINE. *EPJ Techniques and Instrumentation*, 8(1):11, 2021. doi: 10.1140/epjti/s40485-021-00066-7.

[33] 于春蕾, 陈广花, 丁建国, 李明, 肖庆雯, and 阎映炳. SHINE 加速器快联锁系统设计与开发. *核技术*, 47(12):120203, 2024. doi: 10.11889/j.0253-3219.2024.hjs.47.120203.

[34] Yingbing Yan, P. X. Yu, Guanghua Chen, Qingwen Xiao, et al. White Rabbit Based Beam-Synchronous Timing Systems for SHINE. In *Proceedings of the 13th International Particle Accelerator Conference*, pages 2415–2419, 2022. doi: 10.18429/JACoW-IPAC2022-THIYGD1.

[35] B. Efron. Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1):1–26, 1979. doi: 10.1214/aos/1176344552.

[36] Quinn McNemar. Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages. *Psychometrika*, 12(2):153–157, 1947. doi: 10.1007/BF02295996.

[37] Mark D. Smucker, James Allan, and Ben Carterette. A comparison of statistical significance tests for information retrieval evaluation. In *Proceedings of the sixteenth ACM conference on Conference on information and knowledge management*, pages 623–632, 2007. doi: 10.1145/1321440.1321528.

[38] Tetsuya Sakai. Statistical Significance, Power, and Sample Sizes: A Systematic Review of SIGIR and TOIS, 2006-2015. In *Proceedings of the 39th International ACM SIGIR conference on Research and Development in Information Retrieval*, pages 5–14, 2016. doi: 10.1145/2911451.2911492.

[39] Geir Kjetil Sandve, Anton Nekrutenko, James Taylor, and Eivind Hovig. Ten Simple Rules for Reproducible Computational Research. *PLoS Computational Biology*, 9(10):e1003285, 2013. doi: 10.1371/journal.pcbi.1003285.

A 复现与数据说明

随文脚本从冻结文件重建全部新增统计。在项目根目录运行下列命令，可核验 11 种配置、231 条配对排名和 32 条耗时。

```
python3 output/paper-v2/scripts/paper_stats.py --check
```

重采样使用 seed 20261027，重复 1,000 次，经验分位数采用线性插值。数据清单、SHA-256、全部 bootstrap 区间和候选原文保存在`data/paper-statistics.json`；文献核验记录见`data/reference-verification.json`。

论文与图形均保留可编译源文件。正文通过 `main.tex`、`sections/*.tex` 和 `refs.bib` 组织，图形为 180 mm 中文矢量 PDF，公式由 LaTeX 原生排版。`scripts/draw_figures.py` 读取统计快照重绘，`latexmk -xelatex main.tex` 或 `tectonic main.tex` 完成编译；源输入保持只读。完整修改与命令回执见 `CHANGES.md`。

B 主张与证据映射

每条贡献由具体图表与可重算输入支撑。表7给出正文主张的唯一主要锚点，历史解释和原始候选保存在相应数据文件。

表 7 贡献及关键发现的主要证据锚点。路径相对于项目根目录。

主张	主要图表	可复核输入
引用与编码解耦	图1	`papers/rag-thesis/data/corpus.csv` 及 `evidence-snapshot.json`
完整覆盖净增 2 条	表2、表4	`papers/rag-thesis/data/query-ranks-v2.csv`
配对统计与区间	表3、图3	同一逐查询排名；`paper_stats.py`
问答来源连续绑定	图2	`rag/answer.py`、`context.py` 及生产 JSON
父块与片段相差 1 条	图4a	`reports/rag-stage-two-eight-two-reranking.json`
语言互补	表5	`query-ranks-v2.csv` 与 `benchmark.csv`
多查询负收益	图4b	`reports/rag-stage-two-eight-multilingual-retrieval.json`
32 问延迟与分阶段占比	表6、图4c	`production-latency-20261026.csv`
三条原始候选机制	表4及结果分析	`tmp/stage-two-eight-two/original-query-candidates.json`
IOC 过度完整标记	结果6.6节	`reports/rag-production-readiness-20261026.json` 与冻结字段清单