

SHINE/EPICS 风险敏感混合检索 论文驱动科研执行计划（24 周）

边科研、边学习、边写作：所有学习任务直接服务于论文证据链

研究对象	SHINE/FEL 场景中的 EPICS 控制知识检索与控制对象定位
核心问题	如何降低语义相关但区域、设备、信号或限定符错误的危险检索结果
核心贡献	A. 查询条件化对象风险；B. Registry 约束结构反事实；C. 条件性学习路由
执行周期	2026-09-09 至 2027-02-28
最终交付	冻结 Benchmark、可复现实验、统计证据、论文完整初稿与复现包

版本：v1.0 制定日期：2026-09-09

第一篇论文的唯一主线

面向 SHINE/EPICS
控制对象定位，研究风险敏感混合检索。目标不是泛化地“ 搭建一个 RAG ”，而是在召回损失受控时，显著降低语义相似但控制对象错误的危险近邻。

研究边界：只做控制知识检索、证据定位、澄清与拒答；不做故障率估计，不接入真实控制写操作。

论文成立的核心判据

Delta Exposure@K < 0
Delta Recall@K >= -epsilon

只有危险候选暴露显著下降、召回损失可解释且统计结论稳定，才能形成风险敏感检索贡献。答案更流畅、界面更完整均不能替代这一证据。

阶段	必须回答的问题	核心产物	进入下一阶段的条件
1. 数据与问题	控制对象和危险近邻能否被稳定定义？	版本化语料、Registry、Schema、标注规范	数据可追溯，字段可审核
2. Benchmark	能否形成不泄漏、可重复的任务定义？	v0.1 查询、证据、对象、风险标签、划分	双审一致性达到可用水平
3. 基线与 Oracle	现有检索器差异和组合上限有多大？	四专家基线、固定融合、规则、Oracle	证明方法空间存在
4. 风险模型	候选究竟错在区域、设备还是信号？	逐字段风险、风险重排、校准曲线	固定候选池上优于纯相关性与规则
5. 结构反事实	单字段危险近邻能否提供额外监督？	反事实生成器、训练与消融	同数量同难度下仍有增益
6. 泛化与论文	收益能否跨结构、跨时间成立？	OOD、Bootstrap、论文图表与复现包	明确成立范围和失败边界

贡献优先级

A - 核心	查询条件化控制对象风险	对 area、subsystem、device、signal、qualifier、validity 逐字段建模，并作为非负错配代价进入排序。
B - 核心	Registry 约束结构反事实	从正确对象生成只改变一个决定性字段的近邻，区分有效但错误与语法合理但无效。
C - 条件	风险约束学习式路由	仅在 Oracle Gap 足够且严格留出上优于固定融合时保留；否则立即停止增加路由复杂度。
验证手段	Structure-OOD	用于证明或限制泛化主张，不单独包装为算法创新。

02

24 周论文里程碑总表

阶段	日期	科研主任务	课程学习	论文资产与验收
启动周	09-09 至 09-13	固化研究问题、贡献边界、实验台账；建立论文骨架；修订现有综述结构问题。	问题定义、可证伪实验、科研记录规范。	两页《问题定义与实验承诺》；论文目录 v0.1。
W1-W3	09-14 至 10-04	审计文档、Registry、PV/IOC、版本与权限；确定首批 1-2 个可控子系统。	EPICS 层级、PV 命名、数据版本治理、解析工程。	L0 清单、Registry 快照、数据可行性报告；80% 抽查对象可解释。
W4-W6	10-05 至 10-25	构建 L1 实体与 L2 证据；制定标注规范；冻结 Benchmark v0.1。	实体连接、标注一致性、Recall/MRR/nDCG。	80-120 查询；20-30 双审；训练/开发/校准/测试划分清单。
W7-W9	10-26 至 11-15	实现 BM25、Dense、Registry、Metadata；固定融合、规则路由与 Oracle 分析。	BM25、向量检索、RRF、Reranker、Oracle 上限。	基线主表、失败分类、Oracle Gap；决定是否保留学习路由。
W10-W13	11-16 至 12-13	训练查询条件化风险评分；固定候选池比较；校准回答、澄清与拒答阈值。	代价敏感学习、概率校准、Selective Prediction。	逐字段风险模型、风险-召回曲线、规则与学习模型对比。
W14-W17	12-14 至 01-10	先分组后生成结构反事实；比较随机、BM25、ANN 和结构负样本；完成消融。	困难负样本、对比学习、Margin Loss、数据泄漏审计。	反事实脚本、变换记录、负样本审计、同条件训练结果与消融表。
W18-W20	01-11 至 01-31	子系统、设备族、命名模式与时间留出；独立问题族 Bootstrap。	OOD 泛化、置信区间、统计功效与误差分析。	95% CI、泛化表、失败边界；禁止用随机划分结果替代 OOD 结论。
W21-W24	02-01 至 02-28	生成与引用评测；API 仅作复现入口；整理论文、图表、配置和数据说明。	Faithfulness、引用核验、学术写作与可复现研究。	完整论文初稿、图表定稿、复现包、演示示例与已知限制。

执行原则：每一阶段都必须产生可进入论文的数据、表格、方法描述或结论；单纯完成代码模块、看完课程或搭建界面，不视为论文里程碑。

03

启动周与前四周可直接执行安排

周期	数据与科研任务	论文写作任务	学习任务	验收与停止条件
启动周 09-09 至 09-13	建立实验台账；整理版本化目录；把研究范围压缩到控制知识检索与对象定位。	写研究问题、三项贡献边界、论文目录；修订综述重复段落和章节编号。	可证伪问题、实验变量与研究伦理边界。	产生两页研究承诺；无法一句话说明论文问题则不进入数据阶段。
W1 09-14 至 09-20	盘点设计报告、手册、PV 规范、IOC 配置和接口说明；导出固定 Registry 快照；选 1-2 个子系统。	起草“研究场景与数据来源”；记录数据可用性限制。	EPICS、IOC、Record、PV 层级与命名规则。	抽查 30 个 PV；至少 80% 可拆成 area/subsystem/device/signal/qualifier。
W2 09-21 至 09-27	设计实体 Schema；保留原始值和规范值；按标题/表格/步骤切块；建立证据-对象链接。	起草“数据模型与证据单元”；绘制 L0-L3 数据图。	文档解析、实体标准化、版本与 provenance。	抽查 50 个证据块，可回到页码、章节、版本并连接控制对象。
W3 09-28 至 10-04	建立查询类型；标注正确证据、正确对象、危险近邻、风险字段和回答策略；双人试标。	起草“任务定义、风险类型与标注协议”。	标注一致性、问题族分组、风险 taxonomy。	完成 20-30 个双审样本；按分歧修订规范；若对象无法稳定标注则缩小范围。
W4 10-05 至 10-11	扩展至 80-120 个查询；先划分再生成变体；隔离训练、开发、校准与测试。	起草“Benchmark 构建和划分”；建立数据卡。	检索评价、Grouped Split、模板泄漏。	冻结 v0.1；形成查询、证据、对象、风险、split 清单和可重复评价脚本。

第一月禁止事项

不提前接入复杂 Agent	不以 UI 或 API 完成度代替实验	不在测试集上反复改标签和参数	不在划分前生成负样本
---------------	---------------------	----------------	------------

查询条件化风险	$R(q, d) = \sum_j \lambda_j a_j(q) \hat{p}_j(q, d)$	a _j (q) 关闭查询未限定字段；风险表示对象错配代价。
风险感知融合	$S(q, d) = \alpha S_{\text{rel}}(q, d) + (1 - \alpha) \tilde{S}_{\text{RRF}}(q, d) - \gamma R(q, d)$	相关性和融合分数先按开发集方案缩放，再扣除风险。
专家效用	$U_i(q) = \text{nDCG}@K_i - \lambda_r E_i - \lambda_c C_i$	质量减危险暴露和归一化成本；仅用检索前可得特征。
总训练目标	$\mathcal{L} = \mathcal{L}_{\text{rank}} + \beta \mathcal{L}_{\text{risk}} + \eta \mathcal{L}_{\text{cf}}$	同时约束相关排序、逐字段风险和反事实间隔。

实验组	具体方法	控制变量	主要问题
基础检索	BM25；通用 Dense；领域 Dense；Registry；Metadata	同语料、同切块、同 Top-K	不同查询类型最依赖哪个专家？
融合基线	加权融合；RRF；RRF + Reranker；规则路由	相同候选预算	固定策略能达到什么水平？
风险模型 A	纯相关性；Registry 规则；学习式逐字段风险	固定同一候选池	风险下降来自重排还是召回变化？
反事实 B	随机；BM25 hard；ANN hard；结构反事实	同数量、同难度、同模型容量	结构监督是否具有独立贡献？
路由 C	固定混合；规则；仅嵌入；结构特征；风险效用	同预算并先做 Oracle	学习路由是否真的有额外收益？
泛化	随机；子系统；设备族；命名模式；时间留出	独立问题族统计	收益是否越过训练结构边界？

维度	必须报告
基础质量	Recall@K、MRR、nDCG、PV 集合 Exact Match、字段准确率
风险	Exposure@K、危险候选数量、风险类型分层；同时报告零返回率
选择性输出	Coverage 与 Selective Risk；空接收集合记为未定义，不记为零风险
工程代价	P50/P95 时延、实际调用专家数、候选预算
统计	按独立问题族 paired bootstrap, 95% CI；多随机种子；分层样本数

时间	论文部分	本阶段必须写入的内容	配套图表/附件
启动周-W3	1 引言；2 问题定义	控制系统对象错配为何不同于一般不相关检索；任务边界；三个贡献假设。	研究问题图、贡献边界表、风险 taxonomy。
W4-W6	3 数据与 Benchmark	数据来源、L0-L3、Schema、标注协议、分组划分、泄漏控制。	数据流程图、样本统计表、数据卡、标注指南。
W7-W9	4 基线与问题空间	四专家、固定融合、规则、成本定义、Oracle Gap。	基线主表、查询类型分析、Oracle 图。
W10-W13	5 方法 A	风险字段、掩码、融合公式、校准与选择性输出。	模型图、风险-召回曲线、可靠性图。
W14-W17	5 方法 B；6 实验	结构反事实生成规则、有效性审核、损失函数与公平比较。	样本示例、训练流程、消融表。
W18-W20	6 结果；7 讨论	OOD、Bootstrap、失败模式、成立范围和负面结果。	OOD 表、置信区间图、错误案例矩阵。
W21-W24	摘要；结论；附录	最终贡献陈述、局限、复现说明；生成层结论与检索层分开。	最终架构图、配置清单、复现命令、演示案例。

论文资产目录建议

data/	版本化清单、Registry 快照、Schema、划分、数据卡
benchmarks/	查询、证据、对象、风险、问题族、审核状态
configs/	基线、风险模型、反事实、路由、随机种子
results/	逐查询结果、汇总表、置信区间、失败案例
paper/	正文、图表源文件、实验到图表的映射
repro/	环境、运行入口、数据版本、预期输出和限制

规则：任何写进论文的数字都必须能追溯到数据快照、配置、代码版本和逐查询结果；任何图表都不得只保留图片而丢失生成数据。

节点	必须检查	继续条件	不满足时的处置
W3 数据闸门	Registry 完整度、字段可解析率、证据可追溯性	核心对象可稳定标注，抽查解析率达到约定门槛	缩小到可解析子系统，不用扩大概念范围掩盖数据不足
W6 Benchmark 闸门	双审分歧、模板/别名泄漏、划分独立性	任务定义稳定，测试数据不再回流训练	回到标注协议；不开始正式模型比较
W9 路由闸门	$OracleGap = M_{oracle} - M_{best_fixed}$	Oracle 明确高于最佳固定策略，且潜在收益超过复杂度成本	取消学习路由，使用固定混合；C 不进入核心贡献
W13 风险闸门	固定候选池上的 Exposure-Recall 权衡	学习风险优于纯相关性和规则，并保持可校准	采用可解释规则，收缩学习风险模型主张
W17 反事实闸门	同数量、同难度、同容量下的训练增益	对象混淆显著下降并在严格留出上可复现	转为压力测试集或错误 taxonomy 贡献
W20 泛化闸门	子系统/设备族/命名模式/时间留出	至少在预先声明的严格留出上成立	不宣称跨结构泛化，清楚报告适用边界

风险	早期信号	预防措施	应急收缩
数据不足	对象字段缺失、版本不可确认	从高质量资料和 1-2 个子系统起步	只做可解析对象定位
规则已足够	学习模型仅复制 Registry 规则	固定候选池公平比较	转为可解释约束检索
负样本泄漏	相同设备族跨划分、模板高度重复	先分组后生成；问题族 ID 审计	重做 split，作废受污染结果
指标虚高	空返回导致 Exposure 假下降	同时报告零返回率、Coverage	重新定义接收集合和风险统计
范围失控	过早加入状态、波形、Agent 与在线控制	第一篇只做检索和对象定位	移入后续论文路线

07

每周执行机制、周报模板与下一步

周一	问题与文献	围绕本周唯一实验问题精读 2-4 篇直接相关论文；更新 related work 和假设。
周二-周三	数据与实现	完成数据、代码、单元测试和小规模 sanity check；不在此阶段追求漂亮结果。
周四	正式实验	冻结数据、配置和种子；运行正式实验并保存逐查询输出和失败案例。
周五	分析与写作	更新主表、图、论文段落；写清本周结果支持或否定了什么。
周末	补课与复现	只补本周暴露出的知识缺口；复跑关键结果；制定下一周单一目标。

每周必须留下	最低要求
论文文字	至少形成一段可直接进入论文、带证据或实验结果的文字
可复现资产	数据/代码/配置有明确版本；他人可按记录重跑
结果证据	至少一张表、一幅图或一组结构化失败案例
研究判断	明确继续、修改或停止当前路线，而不是只写“下周继续优化”

周报五问

1. 本周试图证伪哪个假设？

2. 使用了哪个冻结数据版本与划分？

3. 结果相对哪个基线变化，置信区间如何？

4. 最典型的三个失败案例是什么？

5. 下周继续、修改还是终止哪条路线？

现在立即开始的三件事

1. 确定首批 1-2 个子系统和 Registry 快照日期。

2. 建立 L0 数据资产表及 30 个 PV 的结构拆分抽查。

3. 创建论文骨架和实验台账，在第一周就开始写“数据来源与问题定义”。

完成这三项后，再进入解析管线和 Benchmark 标注。

资料依据：最终版研究方案、10 页完整研究汇报、4 页组会精简版以及加速器领域 RAG 综述。旧 30 天计划已归档为草稿，不再作为论文主计划。