

SHINE 加速器 RAG 前期准备方案

资料库建设、Benchmark（基准测试）设计与总计划实施路线

给导师的核心结论

建议把课题范围明确为“面向 SHINE/EPICS 控制知识的风险敏感混合检索与控制对象定位”。前期资料库以设计报告、操作手册和 PV/IOC/设备 Registry（注册表）为主体，不依赖目前缺少的系统化维护与故障统计。Benchmark 必须同时标注正确证据、正确控制对象和危险近邻，并采用结构 OOD（分布外）留出，才能验证查询条件化风险、结构反事实负样本和风险约束路由的贡献。

项目	内容
文档用途	与导师确认研究边界、数据准备、标注规模、实验门槛和阶段性交付物
已知数据条件	可获得结构化 PV/IOC/设备关系、设计报告和操作手册；维护记录与故障统计不足
建议论文主线	查询条件化控制对象风险 + Registry 约束结构反事实负样本 + 结构 OOD 泛化
条件性创新	风险约束且成本感知的学习式专家路由；由 Oracle Gap（理想路由增益）决定是否保留
版本	导师确认稿 v1.1 2026-09-08

本次需要导师确认的五件事

- 研究范围是否限定为控制知识检索与控制对象定位，而不把故障诊断作为主任务。
- 能否取得可版本化导出的 Registry，以及哪些 PV/IOC/设备字段可以用于研究。
- 能否安排领域专家参与问题审核和高风险样本复核。
- Benchmark 是否允许发布脱敏结构、问题、qrels（相关性标注）和负样本生成规则。
- 是否接受先做 80-120 道 v0.1 计算 Oracle Gap，再决定是否投入学习式 Router（路由器）。

目录

1. 本确认稿要解决的问题	3
2. 资料库总体结构	3
3. 原始文档资料库：需要什么	4
4. Registry 结构库：论文最关键的数据基础	4
5. 文档证据块与控制对象关联	5
6. 数据清洗、版本化与质量验收	5
7. Benchmark 的目标与设计原则	6
8. Benchmark 问题类型与建议比例	6
9. 用问题族体现结构反事实创新	7
10. 每道问题应保存的 Benchmark Schema	8
11. 标注流程与专家工作量	8
12. 数据划分与结构 OOD 泄漏控制	8
13. 指标体系：不能只看回答准确率	9
14. 如何用 Benchmark 验证学习式专家路由	10
15. 基线、消融与论文证据链	10
16. 总计划实施路线	11
17. 人员、工具与工作量分配	11
18. 主要风险与备选路线	12
19. 分阶段交付物与验收清单	12
20. 建议与导师逐项确认的决策表	12
参考文献	13

1. 本确认稿要解决的问题

这份方案不是最终实验结论，而是开题前的数据与评测设计。需要先把“有哪些可信资料”“什么算正确答案”“什么错误最危险”“训练集与测试集怎样隔离”确认下来，再开始模型训练。若这四件事不清楚，后续即使模型指标很高，也无法判断是方法有效、数据泄漏，还是评价标准过于宽松。

建议的研究对象	
检索对象包含文档证据块和结构化控制对象两类：前者回答“原理、说明和操作依据在哪里”，后者回答“具体是哪个区域、设备、信号、PV 或 IOC”。系统应尽量同时返回答案和可追溯证据。	
范围	内容
纳入主线	设计报告、操作手册、技术说明、PV/IOC/设备 Registry、文档与实体关联、专家问题与风险标注
可作为扩展	少量调试记录、FAQ、会议纪要、报警说明；只有来源和版本可信时使用
暂不作为主线	系统化故障诊断、故障率建模、维护预测；当前缺少连续且可信的维护与故障统计
明确禁止	根据模型常识补写不存在的故障记录；将无来源生成问答直接当成测试真值

2. 资料库总体结构

资料库建议采用“原始资料层 - 规范化实体层 - 文档证据层 - 监督评测层”四层结构。四层的数据生命周期不同：原始资料只读保存；结构化 Registry 可随运行系统更新；证据块随文档版本更新；监督评测数据则需要人工审核并冻结版本。不能把四类数据混成一个向量库后再依赖模型自行理解。



图 2-1 从原始资料到可复现实验的完整数据链。

层级	作用	关键字段	验收目标
L0 原始资料层	保存原文件与 Registry 导出	来源、版本、日期、责任人、敏感级别	能够回到原文复核

层级	作用	关键字段	验收目标
L1 规范化实体层	统一 PV、IOC、区域、子系统、设备、信号	原始值、规范值、解析规则版本	实体可稳定连接
L2 文档证据层	形成可检索、可引用的证据单元	页码、章节路径、表格标题、关联实体	答案可追溯
L3 监督评测层	形成问题、标准答案、危险近邻和划分	审核状态、风险类型、快照、split	训练与测试可复现

3. 原始文档资料库：需要什么

资料类型	主要用途	优先级	整理要求
设计报告	系统目标、设备组成、信号链、控制架构	高	章节和图表结构必须保留
操作手册	操作步骤、前置条件、参数意义、注意事项	高	步骤不可被切散；保留版本
PV 命名规范	名称字段、缩写、区域与设备编码	高	用于解析、反事实生成和 OOD 划分
IOC/EPICS 配置说明	IOC、Record、PV、服务器关系	高	用于结构化关系和有效性校验
设备接口/信号说明	设备、信号、单位和读写方向	高	用于 device/signal/qualifier 标注
调试说明与 FAQ	真实表达、常见混淆和问题形式	中	需要确认来源，不直接当测试真值
维护或故障资料	处置过程与历史案例	低/可选	没有系统统计时不构造故障诊断任务

3.1 每份文档的最小元数据

字段	定义	示例
document_id	稳定且唯一的文档编号	DOC-LLRF-001
title / document_type	标题与类型	Buncher LLRF 操作手册 / operation_manual
subsystem / device_family	归属子系统和设备族	LLRF / BUNCHER
version / effective_date	文档版本和生效日期	v2.1 / 2026-05-10
source_path / owner	来源位置和资料负责人	受控目录 / 子系统负责人
sensitivity / publishable	敏感级别与是否可发布	internal / false
parse_version	解析程序与参数版本	parser-v0.3

导师需要确认

哪些文档是当前有效版本？旧版文档是否保留用于 Temporal Holdout（时间留出）？哪些字段和文本可以脱敏后公开？

4. Registry 结构库：论文最关键的数据基础

Registry（注册表）不是普通的关键词表，而是系统中控制对象的结构化事实来源。至少要能表示 Area（区域）、Subsystem（子系统）、Device（设备）、Signal（信号）、PV/Record、IOC 与服务器之间的关系，并保存快照版本。查询条件化风险、结构反事实负样本和有效性校验都依赖这一层。

字段组	建议字段	研究用途
身份字段	pv_name、record_name、field_name、ioc、server	唯一定位对象并检查重复
控制结构	area、subsystem、device_family、device_instance、signal、qualifier	判断区域/设备/信号错配
语义属性	description、engineering_unit、record_type、read_write	支持自然语言检索和控制语义判断

字段组	建议字段	研究用途
状态与时间	status、valid_from、valid_to、snapshot_date	区分启用、停用、旧版本和时间留出
名称关系	alias、legacy_name、canonical_name	处理别名和历史名称
治理字段	source_id、sensitivity、publishable、parse_version	保证来源可追溯与合规

4.1 Registry 的最低可用标准

- PV 主键稳定；同名冲突、跨 IOC 重复和大小写差异有明确处理规则。
- 至少能可靠解析 area、device 或 signal 中的两个以上层级，否则难以支撑结构风险研究。
- 每次实验记录 snapshot_date 和 registry_version，禁止训练集与测试集使用不明版本的混合快照。
- 保留无法解析和多义对象，不要直接删除；它们应进入 unknown 或 ambiguous 类并单独统计。
- 专家确认 SP、RBV、CMD、STS 等 qualifier（限定符）的工程含义和风险等级。

5. 文档证据块与控制对象关联

文档切块的目标不是得到长度相近的文本，而是得到能够独立支持一个结论的 Evidence Unit（证据单元）。一个完整操作步骤、一个参数定义、一张表格及表头、一个设备功能说明，应尽量保持在同一证据单元中。

要求	建议实现	目的
结构边界	按标题、段落、列表、表格和步骤切分	避免把条件与操作分开
定位信息	page、section_path、table_title、step_number	回答可以回到原文
实体链接	linked_area/subsystem/device/signal/pv	支持文档与 Registry 联合检索
版本信息	document_version、effective_date	处理旧文档与时间一致性
关联来源	explicit、rule_inferred、expert_confirmed	区分直接出现、规则推断和专家确认

不建议

不要只采用固定 500 字或固定 Token（词元）长度切块。固定长度可以作为最大上限，但切块优先服从章节、表格和操作步骤结构；否则 Benchmark 的证据边界会变得含糊。

6. 数据清洗、版本化与质量验收

质量维度	检查内容	建议记录
唯一性	PV 是否跨 IOC 重复；主键是否稳定	重复率、冲突清单
完整性	描述、单位、设备、信号等字段是否缺失	字段缺失率
一致性	同一设备/子系统命名是否统一	规范化映射覆盖率
时效性	停用、改名、别名与旧文档是否可识别	版本覆盖率、过期率
可连接性	文档块能否关联 PV/IOC/设备	链接准确率、链接覆盖率
可公开性	能否生成一致的脱敏字段和公开子集	可发布字段与样本比例

6.1 推荐流水线

1. 冻结原始文件与 Registry 快照，生成校验和并建立数据清单。
2. 解析文档结构和表格；抽样人工核对页码、标题层级和字符编码。
3. 解析 PV 名称并规范化结构字段；输出解析失败和多义清单。

4. 建立文档块与控制对象链接；分别记录自动规则与人工确认结果。
5. 完成质量报告后再生成问题和负样本；数据划分必须早于样本扩增。

7. Benchmark 的目标与设计原则

Benchmark（基准测试）不能只检查系统是否给出一个看起来合理的答案。它需要同时评价：正确知识是否召回、正确控制对象是否定位、危险近邻是否被排除、证据是否可追溯、信息不足时是否会澄清或拒答。

原则	具体要求	原因
证据先行	先从可信文档或 Registry 确定答案，再编写问题	禁止先让模型出题再寻找证据
双重真值	同时保存 gold evidence（标准证据）和 gold entity（标准实体）	避免只评价最终自然语言答案
危险近邻显式化	为核心问题标注 dangerous confusions（危险混淆项）	直接评估区域、设备和信号错配
划分先于生成	先按子系统/设备族/模式划分，再生成问题和负样本	防止命名模板泄漏
版本可复现	保存 document_version 与 registry_version	确保答案与当时系统状态一致
方法无关	题目由任务需求定义，不根据本方法输出反向筛选	避免 Benchmark 偏向自有模型

最能体现创新的设计

每道核心问题除标准答案外，还应提供至少一个真实、词面相似、仅关键结构字段错误的候选。这样才能比较普通相关性检索与控制对象风险建模的差异。

8. Benchmark 问题类型与建议比例

任务	比例	问题示例	主要真值	主要能力
T1 文档知识	20%	Buncher 相位控制采用什么模式？	正确文档段落	基础 RAG 检索
T2 控制对象定位	20%	INJ1 BUNCHER 的 PHASE 回读 PV 是什么？	PV + 结构字段	精确对象定位
T3 危险近邻辨别	25%	在多个相似 PV 中找到指定区域/设备/信号	正确对象 + 危险项	查询条件化风险
T4 歧义与澄清	10%	BUNCHER 的 PHASE PV 是什么？	缺失字段 + 候选范围	拒答/澄清能力
T5 无效标识符/版本	10%	某 PV 当前是否有效？旧名对应什么？	状态 + Registry 快照	有效性与时空一致性
T6 文档-Registry 联合	15%	某信号对应哪个 PV，单位和功能是什么？	文档证据 + PV	多专家联合检索

比例用于 v1.0 规划，不是必须机械执行。真正约束应是：每个关键风险类型具有足够样本，并且训练集、开发集和结构 OOD 测试集均能覆盖必要任务。

8.1 T1：普通文档知识问题

这类题保证系统仍然是一套可用的知识检索系统，而不是只会识别 PV。问题应能够从一个或少量明确证据单元中回答，例如设备功能、参数含义、控制模式和操作前置条件。主要指标为 Recall@K（前 K 位召回率）、NDCG@K（归一化折损累积增益）和 Evidence Recall（证据召回率）。

8.2 T2：控制对象精确定位问题

问题需要明确或隐含 area、subsystem、device、signal、qualifier 中的若干字段，答案是一个或多个 PV、IOC 或设备。除 Exact Set Match（精确集合匹配）外，还要逐字段统计 Area Accuracy（区域准确率）、Device Accuracy（设备准确率）、Signal Accuracy（信号准确率）和 Qualifier Accuracy（限定符准确率）。

8.3 T3：危险近邻辨别问题

这是体现主要创新的核心子集。以查询“INJ1 BUNCHER 的 PHASE 回读 PV”为例，正确答案可以是 INJ1:BUNCHER:PHASE:RBV；危险混淆项可以分别只把 INJ1 换成 INJ2、BUNCHER 换成 CAVITY、PHASE 换成 AMP，或把 RBV 换成 SP。它们对 BM25 和 Dense Retrieval（稠密检索）都可能高度相似，但工程含义明显不同。

风险类型	最小变化	样本要求	建议严重程度
Area Error（区域错误）	INJ1 -> INJ2	真实跨区域相似对象优先	高
Subsystem Error（子系统错误）	LLRF -> Timing	保持设备或信号词面相似	中-高
Device Error（设备错误）	BUNCHER -> CAVITY	候选应在 Registry 中真实存在	高
Signal Error（信号错误）	PHASE -> AMP	只改变信号语义	高
Qualifier Error（限定符错误）	RBV -> SP	回读与设定值必须分开	高
Invalid Identifier（无效标识符）	语法合理但不存在	与有效但错误样本分开报告	高

8.4 T4-T6：澄清、版本与联合问题

题型	问题条件	期望行为	主要指标
歧义问题	缺少区域或设备实例	系统指出缺失字段并请求确认	错误自信回答率
无效名称	命名合理但 Registry 不存在	回答 invalid/unknown，不编造对象	无效标识符识别率
旧名/别名	文档名称与当前 Registry 不同	区分 alias、deprecated 和 active	时间一致性
联合问题	同时问 PV、单位、功能或操作依据	返回结构化实体和文档证据	联合完全正确率

9. 用问题族体现结构反事实创新

不应把每道问题看作互不相关的独立句子。建议从一个经过专家确认的基础问题生成一个 Counterfactual Question Family（反事实问题族），每次只修改一个决定性条件，观察答案是否同步、正确地变化。

成员	问题	唯一变化
基础问题	INJ1 BUNCHER 的 PHASE 回读 PV 是什么？	INJ1/BUNCHER/PHASE/RBV
区域变体	INJ2 BUNCHER 的 PHASE 回读 PV 是什么？	只改变 area
设备变体	INJ1 CAVITY 的 PHASE 回读 PV 是什么？	只改变 device
信号变体	INJ1 BUNCHER 的 AMP 回读 PV 是什么？	只改变 signal
限定符变体	INJ1 BUNCHER 的 PHASE 设定值 PV 是什么？	RBV 改为 SP
歧义变体	BUNCHER 的 PHASE 回读 PV 是什么？	删除 area，正确行为是澄清
无效变体	询问一个 Registry 中不存在的合理组合	正确行为是不编造

$$CC = \frac{N_{\text{correct structural change}}}{N_{\text{counterfactual pairs}}}$$

式（1）Counterfactual Consistency（反事实一致性）：问题关键字段变化后，答案结构也正确变化的比例。

避免人为偏向

反事实问题族的生成规则应在模型实验前冻结，并由 Registry 事实与专家审核决定，不得只保留本方法答对而基线答错的题目。

10. 每道问题应保存的 Benchmark Schema

字段	定义	要求
question / answer_type	问题文本与任务类型	document、pv、device、ioc、procedure、clarification
gold_answers	标准答案，可为集合	一个或多个 PV/IOC/实体状态
gold_entities	结构化正确对象	area、subsystem、device、signal、qualifier
evidence_units	支持答案的文档块或 Registry 记录	必须能回到页码、章节或记录
dangerous_confusions	危险错误候选及错误原因	area_error、device_error、signal_error 等
risk_type / severity	风险类型与严重程度	尽量使用客观类别；严重程度由专家确认
source_id / versions	数据来源和文档/Registry 版本	保证答案可复现
split_group / split_type	划分组与划分方式	subsystem_holdout、pattern_holdout 等
annotation_status	标注处理状态	draft、reviewed、adjudicated、frozen

10.1 一道核心样本的最低验收条件

- 答案能够从指定文档或 Registry 快照独立核验。
- 至少标注一个 gold entity（标准实体）或一个 gold evidence（标准证据）。
- 高风险题至少含一个 dangerous confusion，并说明其错在什么字段。
- 问题不能依赖未写明的口头背景；若信息不足，应标成 clarification_required。
- 记录问题作者、复核者和争议处理结果；测试集冻结后不得根据模型输出改题。

11. 标注流程与专家工作量

阶段	任务	建议角色	产物
A1 出题	从可信证据出发，确定答案后编写自然语言问题	问题作者	问题 + 初始答案 + 来源
A2 结构标注	标注 area/subsystem/device/signal/qualifier	问题作者或数据人员	gold entities
A3 危险项生成	从同 split 的 Registry 选择最小字段变化候选	规则程序	候选 + 风险类型
A4 独立复核	第二人不看模型结果，核对答案、证据和危险项	第二标注者	reviewed 状态
A5 专家裁决	处理高风险项、歧义和严重程度分歧	领域专家	adjudicated 状态
A6 冻结发布	生成数据卡、split manifest 和版本号	课题负责人	frozen benchmark

建议对 15%-25% 的问题进行双重独立标注，报告 Cohen's kappa（科恩卡帕）或 Krippendorff's alpha（克里彭多夫阿尔法）。对客观字段先报告逐字段一致率；严重程度若一致性较低，可将论文主指标收缩为客观错误类型和二元危险近邻判断。

阶段	建议问题数	复核要求	用途
v0.1	80-120	约 20-30 道双标	验证问题定义、专家互补性和 Oracle Gap
v0.5	200-350	约 40-80 道双标	训练简单 Router/Risk Scorer；建立独立开发集
v1.0	500+	关键风险类型各至少 30-50 道	论文主实验；测试集建议至少 150-200 道

12. 数据划分与结构 OOD 泄漏控制

硬性顺序

先按子系统、设备族、文档组、命名模式或时间快照划分数据，再在各 split（划分）内部生成问题、反事实变体和负样本。不能先生成全部样本后随机切分。

划分	测试目标	主要风险	建议定位
Random Split（随机划分）	同分布基础结果	同设备族和命名模板可能泄漏	只作为参考
Document Holdout（文档留出）	测试未见文档	近重复版本可能泄漏	文档级去重
Subsystem Holdout（子系统留出）	测试未见子系统	子系统数量可能少	主要 OOD 测试
Device-family Holdout（设备族留出）	测试未见设备族	别名可能暴露设备族	主要 OOD 测试
Identifier-pattern Holdout（标识符模式留出）	测试未见命名模板	解析规则可能人工包含测试模式	检验模板记忆
Temporal Holdout（时间留出）	旧快照训练、新快照测试	需要可靠版本记录	检验新增、停用与改名

12.1 split manifest（划分清单）必须记录

- 每个问题、文档、实体和 Registry 记录所属的 split_group。
- 用于分组的 subsystem、device_family、pattern_id、document_group 和 snapshot。
- 近重复文档、别名映射和共享设备模板的处理决定。
- 负样本来源 split；任何跨 split 采样均视为潜在泄漏。
- 每次发布的随机种子、脚本版本和数据哈希。

13. 指标体系：不能只看回答准确率

维度	指标	回答的问题
基础检索	Recall@K、MRR、NDCG@K	正确证据或实体是否排在前面
对象定位	Exact Set Match、字段级 Accuracy	PV 集合及 area/device/signal 是否准确
风险暴露	DangerousExposure@K、NMER@K	Top-K 是否包含危险近邻
反事实一致性	CC	问题只改变一个字段时，答案是否正确变化
澄清/拒答	Clarification Accuracy、Risk-Coverage Curve	信息不足时能否避免自信误答
效率	Latency、检索通道数、候选数	学习式路由是否节省计算
统计可靠性	Bootstrap 95% CI、配对检验	改进是否稳定而非偶然

$$\text{NMER@K} = \frac{1}{|Q|} \sum_{q \in Q} \mathbf{1}[\text{TopK}(q) \cap D_q \neq \emptyset]$$

式（2）Near-miss Error Rate（近邻误匹配率）：Top-K 中至少出现一个危险混淆项的查询比例。

$$U(E | q) = Q(E, q) - \beta R(E, q) - \eta C(E)$$

式（3）风险约束专家组合效用：检索质量 Q 减去危险近邻风险 R 和计算成本 C。

论文应同时报告 Recall（召回）与 Risk（风险）的完整权衡曲线，不能只挑选某个风险权重下的最优点。若降低危险近邻的代价是大幅丢失正确答案，则方法不能被称为更安全。

14. 如何用 Benchmark 验证学习式专家路由

学习式 Router（路由器）只有在不同专家确实互补时才值得训练。v0.1 阶段先运行 BM25、Dense、PV/Registry 和 Metadata 四个专家，记录每道问题上各专家及专家组合的召回、危险近邻暴露、延迟和候选数，再计算 Oracle Expert（理想专家）上限。

专家	优势问题	典型风险
BM25 Expert（关键词专家）	PV 片段、缩写、型号、精确术语	容易召回词面相似的跨区域 PV
Dense Expert（稠密专家）	功能描述、同义改写、长问题	可能混入语义相似但设备不同的文档
PV/Registry Expert（注册表专家）	对象存在性、命名字段、IOC 关系	对象真实存在不等于符合当前查询
Metadata Expert（元数据专家）	子系统、文档类型、设备和版本过滤	元数据缺失时可能漏召回

$$\Delta_{\text{oracle}} = \frac{1}{|Q|} \sum_{q \in Q} \left[\max_{E \subseteq \mathcal{E}} U(E | q) - U(E_{\text{fixed}} | q) \right]$$

式（4）Oracle Gap（理想路由增益）：完美选择专家组合相对固定混合策略的理论提升空间。

Go/No-Go 判据

若 Oracle Gap 很小或只在随机划分上出现，学习式 Router 不应作为主创新；采用固定并行检索加候选级风险重排即可。若在结构 OOD 集上仍存在稳定上限，再训练同时优化召回、危险近邻和成本的风险约束 Router。

15. 基线、消融与论文证据链

编号	方法	验证目的
B1-B3	BM25、通用 Dense、领域 Dense	建立单通道能力下限
B4	固定 Hybrid RRF（混合倒数排名融合）	检验是否不需要 Router
B5	APS-style Rule Routing（APS 风格规则路由）	与领域规则方案比较
B6-B7	Metadata-as-text / Metadata Filter	隔离元数据贡献
B8	Semantic Channel / Registry Exact	建立 PV 定位强基线
B9-B11	RouterRetriever-style、MoR-pre、MoR-post	与现有学习式路由和信号融合比较
B12	Candidate Reranker（候选重排序）	区分普通相关性重排与风险重排
B13	普通 Hard-negative Training（困难负样本训练）	隔离结构反事实负样本贡献
Ours	Risk-constrained Router + Candidate Risk + Structure Counterfactual	完整方法

15.1 必做消融

- 去掉 PV/Registry Expert；去掉 Metadata Expert；去掉查询结构特征。
- 去掉 Candidate-level Risk（候选级风险）；仅保留风险约束 Router。
- 仅保留候选级风险；将学习式 Router 替换为固定混合。
- 将结构反事实负样本替换为同数量、同难度的普通 ANN 负样本。
- 分别去掉 area、device、signal、qualifier 和 invalid 风险项。
- 随机划分与每种结构 OOD 划分分别报告；检索和生成评测分开报告。

论文证据链

问题存在性：普通检索在危险近邻子集上确实更容易错；方法有效性：候选风险显著降低 NMER 且 Recall 损失受控；数据贡献：结构反事实优于普通困难负样本；泛化能力：优势在至少一种严格结构留出上仍成立；路由价值：只有 Oracle Gap 和成本收益稳定时才纳入主贡献。

16. 总计划实施路线

阶段	主要任务	交付物	阶段出口
P0 第 1-3 周	数据盘点与权限确认	文档清单、Registry 样例、字段字典、敏感级别	关键数据可得；研究边界确认
P1 第 4-6 周	清洗与 Benchmark v0.1	规范化实体、证据块、80-120 道问题	答案可追溯；标注规则可执行
P2 第 7-9 周	基线与 Oracle	四专家基线、危险近邻统计、Oracle Gap	决定是否训练 Router
P3 第 10-13 周	查询条件风险模型	候选风险评分、规则/学习模型、权衡曲线	降低 NMER 且 Recall 损失受控
P4 第 14-17 周	结构反事实训练	生成器、普通负样本对照、分类消融	反事实样本产生独立增益
P5 第 18-20 周	结构 OOD 与统计	子系统/设备族/模式/时间留出、置信区间	主结论不只在随机划分成立
P6 第 21-24 周	系统整合与论文	检索接口、数据卡、实验表、论文初稿	结果可复现；失败结果也能解释

16.1 建议的前六周具体安排

时间	工作	输出
第 1 周	收集资料目录，不复制敏感内容；与负责人确认最新版本	资料资产表
第 2 周	抽取 2-3 个代表子系统；检查 PV 名称是否可解析	Registry 数据质量初报
第 3 周	确定数据边界、脱敏策略和字段字典	导师确认版数据规范
第 4 周	开发结构切块与 PV 解析；人工抽查 50-100 条	解析器 v0.1
第 5 周	编写 40-60 道基础问题及危险近邻；第二人复核	Benchmark 小样
第 6 周	扩展到 80-120 道；冻结 v0.1 和 split manifest	可运行的首个评测集

17. 人员、工具与工作量分配

角色	职责	投入原则
研究生	资料清单、解析程序、问题初稿、实验与版本管理	主要执行者
领域专家/导师	确认字段语义、抽查答案、裁决高风险与歧义样本	集中投入关键节点
第二标注者	独立复核部分问题和危险项	可由熟悉系统的同学承担
数据负责人	权限、脱敏、Registry 导出和版本确认	确保合规与可复现

17.1 降低专家负担的方法

- 先由程序从 Registry 生成候选和字段差异，专家只做确认与裁决。
- 先完成 80-120 道 v0.1，不在问题定义未稳定时追求大规模。
- 将主观严重度与客观错误类型分开；优先要求专家确认客观字段。
- 使用批量审核界面展示问题、答案、原始证据、正确实体和候选差异。
- 集中审查危险近邻、澄清问题和时间版本问题；普通文档题可抽样检查。

18. 主要风险与备选路线

风险	早期信号	备选路线
Registry 字段不完整	area/device/signal 无法稳定解析	先做部分可解析子系统；采用规则 + 人工字典；收缩风险类别
危险近邻数量少	多数查询没有真实相似对象	将贡献转向对象一致性约束和压力测试集，不强行训练风险模型
专家标注不足	高风险样本长期无法复核	减少主观严重程度；保留客观结构错误；缩小 Benchmark
Oracle Gap 很小	固定混合接近理想专家	删除学习式 Router，集中候选级风险重排
普通负样本同样有效	结构反事实无独立增益	降级为压力测试与错误分类贡献
OOD 性能崩溃	模型只记住命名模板	使用字段无关表示、规范化规则或跨设施公开数据验证
数据不可公开	安全与保密限制	发布脱敏结构、生成规则、数据卡和可公开 qrels 子集
文档覆盖不足	操作或过程问题缺少证据	收缩为 PV/IOC/设备定位，不虚构问题

19. 分阶段交付物与验收清单

交付物	内容	验收标准
D1 数据资产表	文档、Registry、权限、版本、负责人、敏感级别	每项来源可追溯
D2 字段字典	原始字段、规范字段、解析规则、无法解析类别	抽样核对通过
D3 文档证据库	结构块、页码、章节、版本、实体链接	可从检索结果回到原文
D4 Benchmark v0.1	80-120 道问题、证据、实体、危险项、split	可运行四专家与 Oracle
D5 数据质量报告	缺失、重复、冲突、解析、链接和可公开性	明确研究限制
D6 Benchmark v1.0	500+ 问题、测试集冻结、数据卡和标注一致性	支持主实验和统计检验
D7 实验包	配置、种子、模型版本、Registry 快照、结果表	第三方可重跑主要结论

20. 建议与导师逐项确认的决策表

议题	建议	原因	导师确认
研究边界	限定为控制知识检索与控制对象定位	避免依赖不存在的故障统计	同意 / 调整
核心数据	设计报告、操作手册、Registry	足以支撑文档与对象联合检索	同意 / 补充
结构字段	area、subsystem、device、signal、qualifier、status	风险定义与反事实生成的基础	确认可得字段
专家资源	关键样本双标，高风险项由领域专家裁决	保证 Benchmark 可信	确认人员与时间
公开策略	优先发布脱敏结构、规则、数据卡和部分 qrels	增强论文可复现性	确认边界
Router 决策	v0.1 后按 Oracle Gap 决定是否训练	避免把常见路由强行包装为创新	接受 Go/No-Go
主评测	随机集 + 至少一种严格结构 OOD 留出	证明不是命名模板记忆	确认留出对象
主要指标	Recall + NMER + 字段准确率 + CC + 成本	同时衡量效果、风险与效率	确认优先级

建议本次会议形成的结论

确定 2-3 个代表性子系统作为首批数据范围；指定 Registry 与文档负责人；确认 v0.1 的 80-120 道问题规模和复核人员；确认先做 Oracle 与危险近邻统计，再决定学习式 Router 是否进入论文主线。

参考文献

- [1] LV H, YAN Y, MI Q, et al. EPICS IOC and PVs Information Management System for SHINE[C]//Proceedings of PCaPAC 2022. JACoW Publishing, 2023: 107-109. DOI: 10.18429/JACoW-PCAPAC2022-FRO21.
- [2] LV H, YAN Y, WANG H. The data storage system for SHINE[J]. Nuclear Instruments and Methods in Physics Research Section A, 2021, 1002: 165285. DOI: 10.1016/j.nima.2021.165285.
- [3] The control system for SHINE[J]. Nuclear Engineering and Technology, 2025, 57(10): 103714. DOI: 10.1016/j.net.2025.103714.
- [4] HELLERT T, AGLADZE N, GIOVANNONE A, et al. From Natural Language to Control Signals: A Conceptual Framework for Semantic Channel Finding in Complex Experimental Infrastructure[J/EB/OL]. Machine Learning: Science and Technology, 2026; arXiv:2512.18779. DOI: 10.1088/2632-2153/ae8219.
- [5] WU A, et al. Evaluating In-Context Learning for Advanced Light Source EPICS Process Variable Prediction[C]//Proceedings of IPAC 2026. MOP6321, 2026. 最终作者与页码以正式 proceedings 为准。
- [6] LEE H, SOLDAINI L, COHAN A, et al. RouterRetriever: Routing over a Mixture of Expert Embedding Models[C]//Proceedings of AAAI. 2025, 39(11): 11995-12003. DOI: 10.1609/aaai.v39i11.33306.
- [7] KALRA J S, ZHAO X, KIM T E, et al. MoR: Better Handling Diverse Queries with a Mixture of Sparse, Dense, and Human Retrievers[C]//Proceedings of EMNLP 2025. 2025: 11971-11990. DOI: 10.18653/v1/2025.emnlp-main.601.
- [8] ZHAO T, ZHU Y, TIAN Y, et al. R³AG: Retriever Routing for Retrieval-Augmented Generation[C]//Proceedings of ACL 2026. 2026: 20506-20522. DOI: 10.18653/v1/2026.acl-long.939.
- [9] SAINJU R, JAROSZ D, SHANG H, et al. A corrective agentic hybrid RAG and an operations-grounded evaluation for a scientific facility[EB/OL]. arXiv:2607.24663, 2026.
- [10] XIONG L, XIONG C, LI Y, et al. Approximate Nearest Neighbor Negative Contrastive Learning for Dense Text Retrieval[C]//International Conference on Learning Representations. 2021. arXiv:2007.00808.
- [11] CORMACK G V, CLARKE C L A, BUETTCHER S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods[C]//Proceedings of SIGIR 2009. 2009: 758-759. DOI: 10.1145/1571941.1572114.

最终建议

先把资料库做成可核验、可版本化的数据资产，再做模型。Benchmark 的核心不是题目数量，而是正确证据、正确实体、危险近邻和结构留出是否齐全。学习式 Router 保留为条件性创新：数据先证明专家互补和风险差异，模型再决定是否值得训练。