

加速器 RAG 与向量库

30 天学习计划（纯计划版）

2026 年 7 月 13 日 - 2026 年 8 月 11 日

一个月目标

初步掌握向量检索、Qdrant、文档处理、混合检索、Reranker、RAG 生成、引用与评测，并完成一个面向 EPICS、HLA、束测和加速器物理资料的可运行原型。

使用方式：每天按 Day N 开始学习，再在对话中展开当天内容、代码、练习与答疑。

一、学习范围与最终成果

本计划聚焦“向量库 + 加速器文档 RAG”，目标是建立可检索、可评测、可追溯的资料问答系统。一个月结束时应形成以下成果：

- 一个结构清晰、可通过 Conda 或 Docker 复现的 Python 项目。
- 一套覆盖 EPICS、IOC/OPI/PV、HLA、BPM/束测、MBA/光源物理的首批语料。
- Qdrant 向量库，以及 dense、BM25/sparse、混合检索和 reranker 流程。
- 40-50 个带正确文档和页码标注的领域评测问题。
- 一个能返回答案、证据片段、标题、页码和版本的简单 Web 原型。
- 一份检索指标、失败案例、安全边界和后续改进路线的总结。

明确边界

第一版只做文档知识检索与解释，不连接真实 EPICS 写操作，不自动执行 caput、调束或设备控制命令。

二、需要同步补齐的前置知识

模块	本月需要掌握	最低达标准
Python 工程	函数、类、文件、JSON、异常、日志、类型标注、虚拟环境	能将脚本拆成可维护模块
数学基础	向量、矩阵乘法、点积、范数、余弦相似度	能解释检索分数的计算与局限
信息检索	倒排索引、TF-IDF、BM25、Top-K、Recall、MRR	能比较关键词、向量和混合检索
Linux / Git / Docker	目录命令、进程端口、提交分支、镜像容器、卷挂载	能启动 Qdrant 并复现项目
Web API	HTTP、JSON、请求响应、FastAPI 基础	能把检索和问答封装成接口
加速器领域	EPICS、IOC、OPI、PV、HLA、BPM、轨道、MBA 等	能为文档和问题设置正确标签

不要求的前置内容：从零训练大模型、深入推导 Transformer、微调 Embedding、知识图谱和多 Agent。

三、四周推进路线

阶段	主线	核心任务	里程碑
第 1 周	基础与最小原型	理解 RAG、Embedding、余弦相似度、BM25 和 Qdrant；完成小规模检索基线。	最小语义搜索 + Qdrant 基础 + 20 题基线

阶段	主线	核心任务	里程碑
第 2 周	真实资料处理与入库	解析 PDF/PPT/Word，清洗、切块、设计元数据并建立批量入库流水线。	真实加速器资料库 + ingestion pipeline
第 3 周	检索优化与评测	实现过滤、BM25、混合检索、Reranker、术语改写和固定评测集。	混合检索系统 + 40-50 题评测集
第 4 周	RAG 系统化与交付	接入 LLM、引用、拒答、API、界面、测试和安全限制。	带引用的可演示 RAG 原型
第 29-30 天	总评测与整理	完成端到端评测、优化、README、架构图、报告与后续路线。	可复现的月度项目成果

四、30 天逐日学习计划

第 1 阶段：基础与最小检索原型（Day 1-7）

日期	主题	主要任务	当日产出与验收
Day 1 7/13	RAG 全景与项目边界	梳理文档解析、切块、Embedding、向量库、检索、生成、引用的完整链路；明确系统只做资料问答，不连接控制写操作。	画出系统流程图；写项目目标与不做事项。 验收：能口述各模块职责，并说明 RAG 与模型训练的区别。
Day 2 7/14	Python 工程与开发环境	建立 Conda 环境、项目目录、依赖文件、配置与日志框架；复习文件、JSON、异常和类型标注。	可运行的项目骨架与 Git 仓库。 验收：新环境可复现，主程序能读取配置并输出日志。
Day 3 7/15	向量、Embedding 与相似度	复习向量、点积、范数、归一化、余弦相似度；理解文本向量的用途和限制。	一页公式笔记；手算小例子。 验收：能解释相似度高不等于答案正确。
Day 4 7/16	最小语义检索原型	用少量 EPICS、BPM、MBA 文本生成向量，完成 Top-K 语义搜索。	不依赖向量数据库的检索脚本。 验收：至少 10 个问题可返回排序后的相关段落。
Day 5 7/17	传统信息检索基础	理解倒排索引、TF-IDF、BM25、精确词匹配；比较关键词检索与语义检索。	两种检索方式的对比记录。 验收：能判断 PV 名、型号、缩写更适合哪种检索。
Day 6 7/18	Qdrant 核心概念	学习 collection、point、vector、payload、distance、Top-K；本地或 Docker 启动 Qdrant。	Qdrant 实例与连接测试脚本。 验收：能创建库、写入、查询、删除测试数据。
Day 7 7/19	第一周复盘与基线测试	整理本周知识；建立 20 个基础问题，记录语义检索和关键词检索表现。	第一版检索基线报告。 验收：形成问题、期望资料、实际 Top-K、失败原因表。

第 2 阶段：文档处理与向量入库（Day 8-14）

日期	主题	主要任务	当日产出与验收
Day 8 7/20	加速器语料范围与分类	确定首批资料：EPICS/IOC/OPI/PV、HLA、束测、光源物理；建立文档登记表。	语料清单与分类规则。 验收：每份文档有主题、类型、语言、版本和状态。
Day 9 7/21	PDF 文档解析	提取正文、页码、标题和段落；识别扫描版、双栏、公式、表格等风险。	PDF 解析脚本与抽样结果。 验收：抽查页码和正文对应正确，乱码可识别。
Day 10 7/22	PPT 与 Word 解析	提取幻灯片标题、正文、备注及 Word 标题层级；统一成标准文档结构。	PPT/Word 解析模块。 验收：不同格式能输出统一字段。
Day 11 7/23	文本清洗与标准化	清理页眉页脚、重复行、断词、异常空格；保留缩写、单位、公式周边语境。	清洗前后样本与规则清单。 验收：文本可读且未误删关键技术信息。
Day 12 7/24	Chunk 切分策略	比较固定长度、段落、标题层级和滑动重叠；避免拆开定义、公式、表格说明。	至少三种切块方案。 验收：同一问题可比较不同切块方案的 Top-K。
Day 13 7/25	元数据与版本设计	设计 source、page、section、system、device、language、version、status、access_level 等字段。	元数据 Schema 与示例 JSON。 验收：任何检索结果都可定位原文及版本。
Day 14 7/26	批量入库流水线	串联解析、清洗、切块、Embedding、写入 Qdrant；增加重复检测与失败日志。	可重复运行的 ingestion pipeline。 验收：可导入首批真实资料并统计文档数、块数和失败数。

第 3 阶段：检索优化与量化评测（Day 15-21）

日期	主题	主要任务	当日产出与验收
Day 15 7/27	向量检索基线服务	封装 query embedding、Top-K、结果格式和相似度阈值；返回原文、页码和元数据。	统一 search 接口。 验收：输入问题可稳定返回结构化检索结果。
Day 16 7/28	元数据过滤与文档治理	实现系统、设备、文档类型、版本、状态过滤；默认排除废弃版本。	过滤检索示例与版本优先规则。 验收：能限定只搜 EPICS、BPM 或当前有效文档。
Day 17 7/29	BM25 关键词检索实现	为文本块建立关键词索引；处理 PV 名、设备号、英文缩写和精确短语。	BM25 检索模块。 验收：精确术语问题较纯向量基线有明显改善。
Day 18 7/30	混合检索与结果融合	并行执行 dense 与 BM25/sparse 检索；使用 RRF 或加权方式融合排序。	混合检索模块与参数记录。 验收：解释型和术语型问题都能获得较稳定结果。
Day 19 7/31	Reranker 精排	从较大候选集召回，再用 Cross-Encoder 对问题-文本块重新评分。	Top-N 召回 + Top-K 精排流程。 验收：记录精排前后正确证据排名变化。
Day 20 8/1	查询改写与领域术语	建立 IOC、OPI、PV、BPM、MBA 等术语表；支持中英缩写展开和口语问题改写。	术语词典与 query preprocessing。 验收：中文、英文、缩写、口语问法能指向同类资料。
Day 21 8/2	评测集与检索评估	建立 40-50 个领域问题；标注正确文档、页码和答案要点；计算 Recall@K、MRR。	固定评测集与对比表。 验收：能够用数据选择切块、Top-K、混合权重和 reranker。

第 4 阶段：RAG 应用与工程化（Day 22-28）

日期	主题	主要任务	当日产出与验收
Day 22 8/3	LLM 生成与提示词约束	把检索证据交给模型；要求只依据证据回答，证据不足时拒答。	最小问答链与系统提示词。 验收：模型不再脱离资料自由发挥。
Day 23 8/4	引用与可追溯回答	为答案绑定来源编号、标题、页码、章节、版本；检查引用是否支持结论。	带引用的 answer 数据结构。 验收：关键结论均有可点击或可定位来源。
Day 24 8/5	上下文组装与 Token 控制	去重相似块、合并相邻块、控制总长度；兼顾多来源证据与上下文顺序。	context builder 与长度统计。 验收：长问题不会因上下文过长而失败。
Day 25 8/6	FastAPI 后端接口	设计 /ingest、/search、/ask、/documents、/health 等接口和返回格式。	可调用的后端服务。 验收：浏览器或 API 客户端可完成检索与问答。
Day 26 8/7	简单问答界面	用 Streamlit 或简洁网页展示问题、答案、检索片段、来源和过滤条件。	可演示的 Web 界面。 验收：用户能查看答案依据，而非只看到最终文字。
Day 27 8/8	工程质量与自动化测试	补充配置管理、日志、异常处理、单元测试、数据统计和一键启动脚本。	测试目录、配置模板和启动说明。 验收：核心模块可测试，异常不会直接导致服务崩溃。
Day 28 8/9	权限、安全与运行边界	增加 access_level、敏感文档过滤、过期提醒、低置信度拒答；禁止生成或执行真实控制写指令。	安全检查清单与边界说明。 验收：系统定位为知识辅助工具，不替代规程与运行人员。

收尾阶段：总评测与交付（Day 29-30）

日期	主题	主要任务	当日产出与验收
Day 29 8/10	端到端评测与优化	运行完整评测集；定位解析、切块、召回、精排、生成和引用中的瓶颈。	最终指标表与失败案例库。 验收：至少完成一轮有数据依据的参数或策略优化。
Day 30 8/11	项目整理与成果展示	整理 README、架构图、数据规范、演示问题、评测报告、已知问题和后续路线。	可复现项目与月度总结。 验收：他人按说明可启动并完成一次带引用的加速器资料问答。

五、每周检查点

检查点	必须达到	自我检查重点
第 1 周结束	能独立解释完整 RAG 链路；Qdrant 可运行；至少 20 个问题有基线结果。	不要急着接 LLM，先确认检索结果是否真的相关。
第 2 周结束	真实 PDF/PPT/Word 已解析；Chunk 与元数据可追溯；可重复批量入库。	重点检查页码、版本和文档标题是否丢失。
第 3 周结束	dense、BM25、混合检索和 reranker 均可对比；评测集固定。	所有优化必须通过指标和失败案例验证。
第 4 周结束	系统能带引用回答、证据不足时拒答；API 和界面可运行。	答案流畅不是首要标准，证据正确才是。
第 30 天	项目可复现、有 README、架构图、评测报告和下一阶段清单。	保留失败案例，不把演示成功等同于系统可靠。

六、建议的每日执行节奏

环节	建议用时	要求
概念学习	40-60 分钟	理解当天核心概念，整理术语和流程。
代码实践	90-120 分钟	从小例子开始，再接入项目，不只复制代码。
领域资料实践	30-45 分钟	使用真实加速器资料验证，而不是只用通用样例。
测试与记录	20-30 分钟	记录输入、Top-K、指标、错误和原因。
当日复盘	10-15 分钟	回答：学会了什么、仍不懂什么、代码哪里不稳。

七、月底验收清单

- 能够解释向量数据库、普通数据库和关键词搜索的差异。

- 能够从零创建 Qdrant collection，写入带 payload 的向量并执行过滤查询。
- 能够解析并切分真实加速器文档，保留标题、页码、版本和系统标签。
- 能够实现并比较 dense、BM25、混合检索和 reranker。
- 能够使用 Recall@K、MRR、引用准确率和拒答情况评估系统。
- 能够让 LLM 只根据检索证据回答，并在资料不足时明确拒答。
- 能够通过 API 或界面展示答案、证据块和来源。
- 能够说明系统在真实加速器运行场景中的权限与安全边界。

月底判断标准

“初步掌握”不是记住术语，而是能够独立重建一个小型系统、解释每个设计选择、用评测结果发现问题，并知道下一步该优化哪一层。